QCert: Making False-Alarm Guarantees Survive Integer Quantization for On-Board SAR Ship Detection

Zijing Song[a], Xiaoyu Zhang[a,*]

[a] *College of Artificial Intelligence, Nankai University, Tianjin, 300350, China*

Abstract

Deployable SAR ship detectors are calibrated in floating point but executed on fixed-point NPUs — and the acceptance metric, mAP, is blind to the mismatch: mAP integrates over the full ranking, whereas the false-alarm rate $P_{fa} = 10^{-3}$ lives at the 99.9th percentile, exactly the region that int8 quantization perturbs through denominator granularity, accumulated rounding, and potential output saturation. We move the false-alarm contract into integer arithmetic. First, we derive a closed-form bound that propagates per-layer scale factors to P_{fa}, and show that for deployments with per-position null models the denominator of the decision statistic dominates — a 5% quantization error on the null-model scale inflates P_{fa} by 1.6× at $\alpha = 10^{-3}$; the bound is verified on all 12 error levels (our SSDD instance fixes the null scale, where the output-grid mechanism dominates instead, §3.2.3). Second, we give a division-free integer decision rule and a histogram-based integer quantile estimator, so that the contract holds by construction on the deployed graph, the host leaves the inference loop, and the integer threshold is transported across quantization configurations using only two scale tables — zero data, zero re-calibration. On an Atlas 200I DK A2 (Ascend 310B) board we report: transported-threshold P_{fa} drift of 0.046–0.111 dex, versus 2.55 dex (∼300×) without scale conversion; bit-exact reproducibility

*Corresponding author. E-mail: zhangxiaoyu@nankai.edu.cn

of the deployed graph (rate 1.0); P99-latency cross-window spread of only 0.69% (INT8 rerun; 1.76% for the sensor-instrumented FP16 run with flat latency as temperature rose 51.7→53.5 °C) over 40-minute continuous loads (per-window P_{fa} constancy being a direct corollary of integer determinism); per-scene integer quantiles cut the candidate load 4.7–4.9× under rough seas (transparent bucketer, rough subset of 35 frames), with a 0.024 ms decision layer (host-simulated upper bound) and a 1.31× INT8 speedup over FP16; and end-to-end compatibility with $P_d = 0.991$ (7× the pixel-domain CFAR baseline) at only −0.29 mAP points. These measurements are only meaningful on fixed-point hardware — and they show that a threshold should live in the number domain where it is executed. Code and experimental results are available at `https://github.com/tesst/qcert-sar`.

Keywords: SAR ship detection, constant false-alarm rate, post-training quantization, threshold transport, edge deployment, Ascend NPU, integer arithmetic

---

摘要（中文）

可部署的 SAR 舰船检测器在浮点域标定、在定点 NPU 上执行，而验收口径 mAP 恰好看不见这一错配：mAP 是对全排序的积分，误警率 $P_{fa} = 10^{-3}$ 是 99.9% 分位——int8 量化通过分母量化粒度、逐层舍入与潜在的输出饱和恰好只扰动尾部，在 mAP 上几乎不可见。本文把误警率契约搬进整数算术。首先给出闭式界把逐层 scale 传播为 P_{fa} 漂移，并定位分母（零模型尺度）为逐位置零模型部署的主导机制——$\alpha = 10^{-3}$ 处 5% 的量化误差使 P_{fa} 膨胀 1.6 倍；合成验证在全部 12 个误差档成立（本文 SSDD 链路的零模型尺度固定，主导项转为输出网格机制，见 §3.2.3）。随后给出无除法整数判决规则与直方图整数分位数估计，使契约在部署图上按构造成立、host 退出推理回路，并支持仅凭两份 scale 表的免数据阈值搬运。在 Atlas 200I DK A2（Ascend 310B）上的板级实测给出：搬运后 P_{fa} 漂移 0.046–0.111 dex，而不换算高达 2.55 dex（约 300 倍）；同一部署图逐

bit 可复现（bit-exact 率 1.0）；40 分钟连续负载下 P99 跨窗极差仅 0.69%（INT8 复跑；FP16 带传感器运行为 1.76%，温度 51.7→53.5 °C 时延不涨；P_{fa} 逐窗恒定系整数确定性的直接推论）；逐场景整数分位把粗糙海况候选负载压降 4.7–4.9 倍（透明分桶器 rough 子集 35 帧）、判决层仅 0.024 ms（host 仿真上界）、INT8 较 FP16 提速 1.31 倍；端到端检测兼容无损（P_d 0.991，为像素域 CFAR 基线的 7 倍，mAP 仅降 0.29 点）。上述测量只在定点硬件上有意义——它们证明：阈值应当活在它被执行的那个数域里。代码与实验结果已开源：`https://github.com/tesst/qcert-sar`。

关键词：SAR 舰船检测；恒定误警率；训练后量化；阈值搬运；边缘部署；Ascend NPU；整数算术

1. 引言（Introduction）

SAR 舰船检测已高度成熟：在 SSDD 上，主流轻量检测器（YOLO 系、DETR 系）的 mAP50 已达 96–99%，精度赛道接近饱和。与此同时，部署目标正在从地面工作站移向边缘与星上平台——这些平台的算力形态几乎只有一种：**定点 NPU**。以本文使用的 Atlas 200I DK A2 为例，其 8 TOPS INT8 算力对应仅 4 TFLOPS FP16，整板功耗约 24 W。把一个在浮点域训练、标定、验收的检测器部署到定点硬件上，是 SAR 检测走向实机无法绕开的一步。

问题在于：**这个检测器是被浮点世界观标定的。**训练后的阈值、校准流程、验收口径，全部以 FP32 分数为对象。而部署执行的，是一张逐层仿射 int8 量化、舍入由硬件 kernel 决定的图。我们相信” 量化误差很小”——因为 mAP 几乎不动。本文指出，这个信念建立在错误的量纲上。

误警率 P_{fa} 由分数分布的极端上尾决定——$\alpha = 10^{-3}$ 恰恰对应 99.9% 分位数——而 int8 量化的三个机制（分母量化粒度、逐层舍入累积，以及潜在的输出饱和）恰好只扰动这个区域。mAP 是对全部检测按分数排序后

的积分，尾部 0.1% 的变化在其中几乎不可见。我们把这一盲区写成一条显式的不蕴含关系（式 3.10）：

$$\left|\Delta\,\mathrm{mAP}\right| < 1 \text{ 点} \quad \not\Longrightarrow \quad R = \frac{P_{fa}^{\mathrm{INT8}}}{P_{fa}^{\mathrm{FP32}}} \approx 1.$$

这就是本文占据的空隙：**所有 SAR 检测论文只报 mAP；所有 PTQ 论文也只优化 mAP。尾部是两边的盲区。**

这个空隙不是思想实验。我们在真实定点板（Ascend 310B）上测量同一模型、同一测试集的 FP16 与 INT8 两个版本：mAP50 从 98.27 降到 97.98（−0.29 点，统计不可区分），而精度不变性比 $R = 0.969$——量化本身对本模型是安全的。但这恰恰暴露了范式错误的全貌：$R \approx 1$ **没有机制保证**。一旦量化配置或校准集改变（而非" 同一.om 的两种精度"），浮点阈值的错误搬运会把 P_{fa} 推高 300 倍（§4.7 设置 2 的" 不换算" 列）；"量化误差很小" 这一经验，对配置变化没有任何预言能力。

为什么 P_{fa} 值得单独守门？因为它是**运行契约**：在星载/边缘链路中，P_{fa} 直接决定下行带宽占用、虚警复核的人工作量、以及后续跟踪器的关联负担。检测器可以对 99% 的场景给出漂亮 mAP，却在量化配置改变、阈值不做整数换算时漏出 300 倍的虚警——而部署方对此一无所知，因为从来没有人标定过" 量化后的检测器"。

定点算术有一项被忽视的 redeeming property：**它是确定的、且可读。**同一 `.om` 在同一设备上逐 bit 可复现（本文实测 bit-exact 率 1.0，§4.5）；每一层的量化参数（scale、zero-point）在编译期固定且对使用者可读。浮点 GPU 没有这两条——它的 kernel 选择是运行时的、累加顺序不固定，分数不落在任何编译期可读的整数格点上（即便 explicit-QDQ 框架导得出 scale 表，"阈值取整到格点" 在浮点域仍无定义）。本文的全部方法，就是把误警率契约搬进这个" 确定性 + 可读" 的整数世界，使契约**按构造成立**，而不是靠实测祈祷。

具体地，本文给出：

- **C1　解析界与免数据阈值搬运。**命题 2 给出误警率漂移的闭式界

$|\Delta P_{fa}| \le L\delta$，其中 δ 完全由 scale 表算出、不需要任何新数据（§3.3.4）；一阶预言 $\Delta \ln P_{fa} \approx z^2 \varepsilon_\sigma$ 指出分母（零模型尺度 σ）的量化粒度主导漂移——$\alpha = 10^{-3}$ 处 σ 的 5% 量化误差使 P_{fa} 膨胀 1.6 倍。在此之上，整数阈值可按 scale 比值在配置间纯函数搬运（式 3.26），**零数据、零重标定**。这项能力在浮点 GPU 上无处定义：搬运规则是整数格点间的纯函数映射，依赖" 同.om 逐 bit 可复现" 与"scale 编译期可读" 的合取，而浮点流水线没有承载判决阈值的全局格点（§3.6.1）。

- **C2　无除法整数判决层**。判决 $(s-\mu)/\sigma > \lambda$ 经交叉相乘化为 64 位整数比较（式 3.21），无除法、无浮点、无排序；配直方图整数分位数估计，标定为 $O(n)$ 单遍。判决与推理合并为单一静态图，host 只做 DMA——实测判决层耗时 0.024 ms，比 3 ms 预算低两个数量级（§4.9）。
- **C3　只有定点板能做的五组测量**。饱和审计（E2）、跨实现判决差异与 bit-exact 复现（E3）、阈值搬运（E5）、40 min 热稳态（E6）、误警→负载耦合（E7）。这些数字在纯 GPU 实验中没有意义——比如"40 分钟热稳态下 P_{fa} 零漂移"，只在整数确定性的硬件上是定理而不是巧合。

在 Atlas 200I DK A2 上，全部测量给出一致结论：搬运后 P_{fa} 贴近 α（漂移 0.046–0.111 dex，而不换算漂移最高 2.55 dex）；40 min 连续运行 P_{fa} 逐窗恒定（整数确定性必然）、P99 跨窗极差 0.69%（INT8 复跑）/1.76%（FP16 带传感器，温度 51.7 → 53.5 °C 时延不涨）；粗糙海况候选负载降 4.7–4.9 倍、INT8 较 FP16 提速 1.31 倍；端到端检测兼容无损（P_d 0.991 vs CA-CFAR 0.139，mAP 仅降 0.29 点）。

我们不提出新的检测器；我们让既有检测器在定点硬件上敢承诺误警率。

2. 相关工作（Related Work）

2.1. SAR 舰船检测：饱和的精度赛道

SSDD（1160 图，RadarSat-2/TerraSAR-X/Sentinel-1 多传感器）[1] 与 HRSID（5604 图，0.5–3 m 分辨率）[2] 是两条主流基准。近期轻量检测器把 SSDD mAP50 推到 96–99%：AC-YOLO（YOLO11 基，96.7%）[3]、BESW-YOLO（YOLOv8n 基，97.3%）[4]、LSD-DETR（97.3%）[5]、LAMFDet（99.5%）[6]。这些工作均未报告实测虚警率，更未报告量化前后虚警率的差（CFAR 一线以 P_{fa} 为设计目标，但见 §2.2，其契约建立在像素幅度分布与浮点 DSP 两个本文不继承的前提上）。所有深度检测方法的阈值 0.25/0.5 是调参调出来的，没有标定程序；部署数字只有 GPU FPS 与 FLOPs。本文的靶子正是这两条事实：mAP 饱和且对虚警不敏感，领域需要换指标。

2.2. 恒定误警检测：从 *CFAR* 到学习型 *CFAR*

经典 CFAR（CA/OS/GO/SO）[8] 对杂波幅度分布（K 分布、G^0、Weibull）建模像素域阈值，是" 误警率契约" 思想的源头。但它有两个本文不继承的假设：**它建模像素幅度而非深度检测器响应**，判别力弱，近岸/多目标场景 CFAR 窗被污染后" 恒定" 即失效；**它工作在浮点或定点 DSP 上，从不讨论" 量化后的 CFAR 是否还是 CFAR"**。CFARnet [9] 把 CFAR 思想搬进学习检测器，在损失中软惩罚零假设下分数分布的不一致，但推理仍是固定阈值、仍是 FP32、无有限样本保证。本文的位置：**不是回到 CFAR，也不是在损失里" 鼓励"CFAR**，而是把判决阈值变成一个在整数算术上成立的可证统计量——继承契约，丢弃分布假设与浮点假设。

2.3. 检测器的训练后量化：均值意义上的精度，尾部量纲上的漂移

这是本文最直接的邻居。PTQ for detection 的现状是：研究几乎全部以 mAP/AP 为目标——Inlier-Centric PTQ（ICLR 2026）[10] 指出检测任务的量化误差由" 与目标特征相似的困难背景（inlier）" 驱动，据此设计校准与重构策略，**验收口径仍是 mAP**；Vitis AI 官方精度验证流程 [11] 要求 INT8 与浮点基线的 mAP 差 $\leqslant$ 1%，否则回去改校准集——**整个生态的验收就是 mAP**；QAT 家族以重训与标注为代价换 mAP，本文不采用。

本文的切割一句话：**PTQ 把量化误差当均值意义上的精度损失去最小化；本文把它当尾部量纲上的统计漂移去界住。** mAP 是对全排序的积分，$P_{fa} = 10^{-3}$ 是 99.9% 分位——尾部误差在 mAP 上几乎不可见（式 3.10 的不蕴含关系，§4.2 实测）。我们不是" 做得更好的 PTQ"，而是**换了一个被优化的量**。

2.4. INT8 的可移植性：从" 测量不一致" 到" 界住并恢复"

Is INT8 Portable? [12] 实测：FP32 在 1000/1000 用例上逐 bit 一致；共享同一整数 kernel 的 INT8 也 1000/1000；但**跨 kernel/跨平台只有 958–965/1000 一致**。这说明 INT8 的不可移植是事实而非工程瑕疵——"在 FP32 下标定阈值、在 INT8 上推理" 在原理上就不成立。它没做的是：不一致对下游统计量（尤其尾分位数）的**解析界**；在整数域内**恢复契约**的判决规则；**免数据**把阈值搬到新配置的机制。本文恰好给出这三件（Prop.2、式 3.21、式 3.26），把" 不一致" 从" 报告一个百分比" 变成" 可预测、可界住、可搬运的量"。

2.5. 不确定性与 conformal prediction

SeqCRC [13] 等用**带标签校准集**给出覆盖保证 $P(\text{真值} \in \text{预测集}) \geq 1-\delta$。四点区别：①保证对象（覆盖/召回 vs 误警）；②标签需求（需带标注校准集 vs 零标注杂波位置）；③分布来源（留出真实样本 vs 可生成的零分布，样本量可达 10^4–10^5，α 可更小）；④**保证作用的模型**——conformal 的保证作用于校准时的那个浮点模型，本文的保证作用于**部署后的整数模型**，这中间隔着量化误差分析（C1），conformal 没有这一层。诚实地说，数学工具（秩统计量/可交换性）同源，本文主动承认。

2.6. 边缘/星上部署实测：只有 FPS，没有契约

GPU 边缘实测已有先例：嵌入式 GPU + TensorRT 混合精度在 640×640 下达 208 FPS、6.2 W [14]——标题含" 量化感知"，但**只报 FPS 与 mAP，不报 P_{fa}**；FPGA 在轨实现了 Stripmap 原始数据实时检测 [15]；昇腾生态（ultralytics 官方 Ascend 集成 [16]、AMCT、ATC [18]）打通了 ONNX →

OM 的工具链。本文的两条空白：没有一篇测过” 量化前后 P_{fa} 变了多少”，也没有一篇测过” 误警率→候选数→后处理尾时延” 的耦合。本文的 C3 五组测量（§4.4–§4.9）正是补这两条空白。

2.7. 小结：四列对照

Table 0　相关工作对照（①优化对象是 mAP 还是尾分位数；②是否显式建模背景/杂波分布；③结论是否在定点整数算术上成立；④是否有板级实测）

工作线	①优化对象	②背景/杂波建模	③定点整数算术上成立	④板级实测
SAR 检测 SOTA（YOLO/DETR 系）	mAP	✗	✗（从未讨论）	✗（仅 GPU FPS）
PTQ for detection（Inlier-Centric PTQ 等）	mAP	⚠（inlier 背景，仍为 mAP 服务）	✓✓（在 INT8 上）	⚠（多为 GPU/仿真）
Is INT8 Portable?	—（不涉及检测指标）	✗	✓✓（测量一致性）	✓✓（多平台）
QAT 家族	mAP	✗	✓	⚠
经典 CFAR（CA/OS/GO）	尾分位数（P_{fa}）	✓✓（像素幅度）	✗（浮点/DSP，不讨论量化）	✗
CFARnet	P_{fa}（软惩罚）	⚠	✗（FP32）	✗

工作线	①优化对象	②背景/杂波建模	③定点整数算术上成立	④板级实测
conformal 检测（SeqCRC）	覆盖（非误警）	✗	✗（FP32 模型）	✗
跨域/TTA/免反传自适应	mAP	✗	✗	✗
边缘 SAR 部署（GPU/FPGA/Ascend）	mAP + FPS	✗	⚠（跑得动，不讨论契约）	✓✓
本文 QCert	**尾分位数（P_{fa}）**	✓✓（零标注零模型，且**被量化**）	✓✓（按构造成立 + 解析界）	✓✓（Atlas 200I DK 实测）

读法：第①列把本文与全部 PTQ/QAT/检测工作分开；第②列把它与 conformal 和普通 PTQ 分开；**第③列是新增列，也是”换到 Jetson 上本文就不成立”的那一列**；第④列提供唯一性证据。四列全勾是本文唯一需要的辩护。

3. 方法（Method）

本章给出 QCert 的完整方法体系：从误警率契约的形式化（§3.1）、定点部署算术模型（§3.2），到量化破坏判决的三个机制与可证伪的误差界（§3.3），再到按构造成立的无除法整数判决层（§3.4）、整数分位数估计（§3.5）、免数据阈值搬运（§3.6）与整体静态流水线（§3.7）。全章围绕一个核心命题：**阈值标定在浮点域、推理在定点域，是一个静默失效的范式错误；本文把误警率契约搬进整数算术，使其在部署图上按构造成立。**

3.1. 误警率契约与记号

3.1.1. 判决统计量与契约

设输入 SAR 场景为 x，检测器 f_θ 输出逐位置分数场 $s(u) \in \mathbb{R}$（经 sigmoid 的原始 logit 或其反变换），u 为空间位置。引入零模型（null model）给出的逐位置一、二阶统计量 $(\mu(u), \sigma(u))$，定义标准化判决统计量

$$z(u) \;=\; \frac{s(u) - \mu(u)}{\max\big(\sigma(u),\, \varepsilon\big)}, \qquad \varepsilon > 0. \tag{3.1}$$

在杂波位置集合 $\Omega_{\text{clutter}}(x)$（不含真实目标，构造见 §3.1.3）上，取 $1-\alpha$ 分位数作为逐场景阈值

$$\lambda(x) \;=\; \text{Quantile}_{1-\alpha}\Big(\big\{\, z(u) :\, u \in \Omega_{\text{clutter}}(x) \,\big\}\Big), \tag{3.2}$$

判决规则为

$$\hat{y}(u) \;=\; \mathbb{1}\big\{\, z(u) > \lambda(x) \,\big\}. \tag{3.3}$$

式 (3.2) 给出**逐场景模式**的阈值。与之并列的是**全局模式**：把全部标定场景的杂波位置合并为混合池，取单一阈值

$$\lambda_{\text{glob}} \;=\; \text{Quantile}_{1-\alpha}\Big(\bigcup_{x \in \mathcal{X}_{\text{cal}}} \big\{\, z(u) :\, u \in \Omega_{\text{clutter}}(x) \,\big\}\Big), \tag{3.2a}$$

判决时以 λ_{glob} 替换式 (3.3) 中的 $\lambda(x)$。两模式共享同一契约框架，但优化目标不同、不可兼得：

模式	标定池	n_{cal} 量级	优点	代价
全局（式 3.2a）	跨场景混合	大（$\sim 10^5$）	$\mathbb{E}[P_{fa}]$ 的标定误差最小（E9：err 0.0185 dex）	条件误警率随场景变化——粗糙海况 $P_{fa}(x) > \alpha$，候选负载随海况恶化（E7）
逐场景（式 3.2）	单场景	小（$\sim 4 \times 10^3$）	$P_{fa}(x) \approx \alpha$ 逐场景成立，候选负载 $\approx \alpha\, n_{\mathrm{cell}}$ 与海况解耦（E7）	标定方差大（E9：err 0.201 dex），且受下界 $\alpha \geq 1/(n_{\mathrm{cal}}+1)$ 约束

二者是同一契约的两个合法运行点：期望精度敏感的链路取全局模式，负载/尾时延敏感的链路取逐场景模式。本文 E7 的负载抑制主张用逐场景模式、E8/E9 的精度主张用全局模式，各节分别标注，不混读。

则实测像素级虚警率

$$P_{fa}^{\mathrm{pixel}} \;=\; \frac{\#\{\, u \in \Omega :\, \hat{y}(u) = 1 \,\}}{|\Omega|}, \tag{3.4}$$

其中 Ω 为与 $\Omega_{\mathrm{clutter}}$ 独立构造的测量集。式 (3.4) 即**误警率契约**。这里必须精确陈述契约的统计含义——它不是" 对任意场景恒有 $P_{fa} \leq \alpha$"的硬保证（有限样本下不可能），而是：

$$\mathbb{E}[P_{fa}] = \alpha, \qquad \mathrm{Var}(P_{fa}) \leq \frac{\alpha(1-\alpha)}{n_{\mathrm{eff}}+1}, \tag{3.5}$$

其中 n_{cal} 为参与标定的杂波位置总数，n_{eff} 为块抽样折算的有效独立块数（见 §3.1.3）。三点必须如实声明：

(i) 期望等式只需可交换，不需要独立。对可交换序列，序统计量的秩论证精确给出 $\mathbb{E}[P_{fa}] = \alpha$；空间相关不破坏期望，只放大方差——方差界中的 n_{eff} 即相关性的折算。可达名义水平有下界 $\alpha \geq 1/(n_{\text{cal}}+1)$：本文逐场景标定 $n_{\text{cal}} \approx 4 \times 10^3$（每场景杂波 cell 数），下界 $\sim 2 \times 10^{-4}$，$\alpha = 10^{-3}$ 可达；块抽样 keep 下降时 n_{cal} 同步缩小，keep= 1/16 档 $n_{\text{cal}} \approx 5 \times 10^2$、下界升至 $\sim 2 \times 10^{-3} > \alpha$——契约在该档本不可达，E9 实测该档 $P_{fa} = 4.7 \times 10^{-3}$ 恰被顶到 $1/n_{\text{cal}}$ 量级（Table 10a），是下界的直接印证而非异常。

(ii) 契约控涨落，不控偏差。式 (3.5) 的期望是相对于标定分布而言；§3.1.3 的纪律要求测量集 Ω 与 Ω_{clutter} 不同构造，二者间的系统性分布偏移表现为 $\mathbb{E}[P_{fa}]$ 对 α 的固定偏差，不在秩统计量界覆盖范围内。本文以偏离度 D（式 3.7）如实暴露之：E0 中 FP16 的 pooled $P_{fa} = 1.60 \times 10^{-3}$ 本身即偏离 α 约 60%（标定与测量构造差异所致），与量化无关（$R = 0.969$）。契约承诺" 围绕可达工作点的涨落被界住"，工作点本身的偏差由 D 暴露而非掩盖。

(iii) 验收口径。工程验收以 $|\log_{10}(P_{fa}/\alpha)|$ 度量守约程度，以标定噪声底（同数据完全重标定后的残余偏离，见 §4.7/§4.11）为参照；全部标定结果附带 n_{cal} 与 n_{eff}，而非只报名义 n。

3.1.2. 主指标：精度不变性比

本文的核心观测量不是 mAP，而是**精度不变性比**

$$R \;=\; \frac{P_{fa}^{\text{INT8}}}{P_{fa}^{\text{FP32}}}, \qquad |\log_{10} R| \text{ 为报告量,} \tag{3.6}$$

以及**契约偏离度**

$$D \;=\; \left|\log_{10} \frac{P_{fa}^{\text{INT8}}}{\alpha}\right| \;\xrightarrow{\text{跨海况}}\; D_{\max} = \max_{\text{桶}} D. \tag{3.7}$$

R 的判据分两级，全文统一使用：

- **存在性门** $R \geq 1.5$：量化使虚警率**恶化 1.5 倍以上**才视为" 静默失效存在" 的硬证据（E0 用）。$R \approx 1$ 或 $R < 1$ 表示未观测到恶化，判 NO-GO——**这不是说方法失败，而是说该配置下失效不存在**，审计如实报告阴性。
- **不变性带** $|\log_{10} R| \leq 0.176$（即 $R \in [0.67, 1.5]$）：量化前后契约等价的验收带（E8 用更严的 $R \leq 1.2$）。搬运/判决层的全部主张都以 R 落在不变性带内、且偏离度 $|D|$ 不超过标定噪声底为合格。

3.1.3. 三套必须分离的集合（防循环论证）

集合	构造	用途	禁止
量化校准集 C_{quant}	三海况各 ≥ 64 张真实 SAR 图（分层）	AMCT 定 scale/range	只取平静海况（会把 range 定小→饱和）
契约标定集 Ω_{clutter}	GT 框外扩保护带 g px 后的杂波位置 + 无目标裁片，块抽样	求 $\lambda(x)$	使用框内像素
测量集 Ω	与 Ω_{clutter} 不同构造	报 P_{fa}	与 Ω_{clutter} 重合

块抽样（block sampling）把 Ω_{clutter} 划成 $B \times B$ 块（$B = 64$ px），按比例 k 抽取整块，缓解空间相关导致的有效样本虚高：

$$n_{\text{eff}} = \frac{|\Omega|}{B^2} \cdot k. \tag{3.8}$$

关键区分：AMCT 用" 图像" 选 range，本文用" 杂波位置" 选分位数——两者优化的不是同一个量。这一区分本身就是本文的一条发现。

3.2. 定点部署算术模型与三条假设

3.2.1. 逐层仿射 *int8* 模型

检测器 f_θ 与零模型被编译为**单一静态图**，激活为逐层仿射 int8 量化

$$a_q \;=\; \mathrm{clamp}\Big(\mathrm{round}\big(\tfrac{a}{\Delta_l}\big) + z_l,\, -128,\, 127\Big), \tag{3.9}$$

其中 Δ_l（scale）与 z_l（zero-point）为第 l 层的量化参数，**编译期固定且可读**。反量化为 $\hat{a} = \Delta_l\,(a_q - z_l)$。对单条目输出头（三检测头 cv3.$\{0,1,2\}$），其量化步长按 cell 数加权几何平均聚合为标量（见 §3.6.2）。

3.2.2. 三条显式假设

本文全部结论建立在以下三条假设上，论文必须显式声明：

- **A1（同设备逐位可复现）**：同一 `.om` 在同一设备上逐 bit 可复现（整数 kernel 确定性）。这是" 热稳态不影响 P_{fa}"与" 搬运规则可定义" 的地基。
- **A2（跨实现不一致）**：不同设备 / 不同量化配置下，int8 输出不保证一致（不同 kernel 累加顺序→舍入不同→尾部次序不同）。
- **A3（量化配置可读）**:每层 (Δ_l, z_l) 与输出 range 对使用者可读（AMCT/ATC 产物）。

在 A1–A3 下，本文主张：**误警率契约可以在整数算术上按构造成立，并在 A2 的情形下被解析界覆盖。**

3.2.3. 部署实例化：本文 *SSDD* 链路的 μ、σ 是什么

式 (3.1) 的 $\mu(u), \sigma(u)$ 是一般化框架（任意逐位置零模型均适用），其实例化必须显式交代，否则判决层的整数码 μ_q, σ_q 无定义。本文分两个层次：

- **一般框架**：$\mu(u), \sigma(u)$ 为逐位置零模型统计量（如杂波局部均值/标准差），与 s 一样经仿射量化（式 3.9）得整数码 μ_q, σ_q。合成审计实验（E1/E4/E9 合成项）采用该完整形式。

- **本文 SSDD 部署实例（全部板级实验所用）**：检测器的 raw logit 分数场**直接**作为判决统计量，即退化情形

$$\mu(u) \equiv 0, \qquad \sigma(u) \equiv \sigma_0 \ \text{(固定常数)}. \tag{3.9a}$$

此时 $\mu_q \equiv 0$、$\sigma_q \equiv \mathrm{round}(\sigma_0/\Delta_\sigma)$ 为编译期常量；Δ_σ 是**判决层自选的归一化网格**（本文取 1/128，见 §3.6.2），是设计参数而非 PTQ 产物。代入式 (3.1)，$z(u) = s(u)/\sigma_0$，分位数阈值 λ 与 σ_0 一同被吸收进 λ_{int}（§3.6.1），判决退化为" 分数场 $>$ 整数阈值"。

这带来两个后果，必须如实声明：

1. §3.3.1 的**分母机制（ε_σ 项）在本文部署实例中不起作用**——σ 是固定常数，不存在 σ 的量化误差。该机制是" 采用逐位置 σ 的更一般零模型部署" 下的主导威胁，由合成实验 E1/E4 覆盖；本文 SSDD 实例中，主导威胁是**输出网格机制**（Δ_s，§3.3.3），这正与 E5 实测一致（Δ_s 变 10× 时不换算漂移 300×）。
2. 选用 logit 作判决统计量的依据：检测器经 BCE 训练后 logit 尾部近似单调于杂波强度，其分位数阈值即" 像素级 CFAR-like" 阈值；本文不主张 logit 是最优零模型统计量，逐位置 μ/σ 的推广留作后续工作。

3.2.4. 为什么 mAP 看不见这个问题

mAP 是对全部检测按分数排序后的积分，对 99.9% 分位不敏感；而 $P_{fa} = \alpha = 10^{-3}$ 恰恰由该分位决定。因此存在一个宽区间：

$$\left|\Delta\,\mathrm{mAP}\right| < 1 \text{ 点} \quad \not\Longrightarrow \quad R \approx 1. \tag{3.10}$$

即 mAP 几乎不动、而 P_{fa} 可变数倍。**这就是本文占据的空隙**——现有 PTQ 研究全部在优化 mAP。

3.3. 量化破坏判决的三个机制与误差界（*C1* 理论）

设量化扰动 $\hat{s} = s + e_s$、$\hat{\mu} = \mu + e_\mu$、$\hat{\sigma} = \sigma + e_\sigma$，其中

$$|e_s| \le \tfrac{\Delta_s}{2}, \qquad |e_\mu| \le \tfrac{\Delta_\mu}{2}, \qquad |e_\sigma| \le \tfrac{\Delta_\sigma}{2}. \tag{3.11}$$

3.3.1. 机制一：分母机制（一般零模型部署的主导项；本文 *SSDD* 实例中不起作用）

适用范围声明：本机制要求 $\sigma(u)$ 为参与量化的逐位置量。本文 SSDD 部署实例中 σ 为固定常数（§3.2.3），不存在该误差源；本机制针对的是采用逐位置 σ 的更一般零模型部署，其数值验证由合成实验 E1/E4 承担。

对式 (3.1) 一阶展开：

$$\hat{z} - z \;\approx\; \frac{e_s - e_\mu - z\, e_\sigma}{\sigma}. \tag{3.12}$$

当 z 中等偏大（判决关心的正是尾部），$z\, e_\sigma$ 项主导，定义**实测量化步长比**

$$\varepsilon_\sigma \;=\; \frac{\Delta_\sigma}{2\sigma}, \tag{3.13}$$

则 $\hat{z} - z \approx -z\,\varepsilon_\sigma$。对高斯上尾 $P_{fa}(z) = 1 - \Phi(z)$，由 $\mathrm{d}\ln(1-\Phi)/\mathrm{d}z = -\phi/(1-\Phi) \approx -(z + 1/z)$ 得

$$\ln \frac{P_{fa}(\hat{z})}{P_{fa}(z)} \;\approx\; z^2\, \varepsilon_\sigma. \tag{3.14}$$

式 (3.14) 是本文最重要的一阶预言：**虚警率漂移随 z^2 放大、随 ε_σ 线性放大**。在 $\alpha = 10^{-3}$（$z \approx 3.09$，$z^2 \approx 9.55$）下（一阶上界量级；E1 实测为预言的 $1/2 \sim 1/24$，界是保守的，见 §4.3）：

ε_σ	ln 倍数 $z^2\varepsilon_\sigma$	P_{fa} 倍数 $e^{z^2\varepsilon_\sigma}$（上界量级）
2%	0.19	×1.21
5%	0.48	×1.63
10%	0.95	×2.65
20%	1.91	×7.0

推论（一般框架下）：在逐位置 σ 的部署中，σ 的量化粒度是首要矛盾，而非 s 的精度。这给出两个设计：① σ 用对数域参数化；②判决中**消除除法**（§3.4）。

该推论的修正（如实声明）：合成消融 E4 表明，对数域/逐通道 σ 仅带来 $\leq 1.85\times$ 改进，未达到预言的 $\geq 5\times$（P1 不成立，§4.6）。因此本文把"σ 项主导" 降级为**一阶标度律**（$\Delta \ln P_{fa} \sim \varepsilon_\sigma^2$，实测指数 $1.96 \approx 2$，成立）与**保守经验界**（Prop.2，成立），不再主张"σ 粒度改进可带来数量级收益"。本文 SSDD 部署实例中 σ 固定（§3.2.3），该推论不直接适用。

3.3.2. 机制二：输出饱和（定点独有）

score head 的输出 range 由校准集统计得到。高杂波场景中强回波使 s 撞上 int8 上界，大量位置得到同一最大整数，产生**并列（tie）**：

$$\text{并列} \Rightarrow \text{排序信息丢失} \Rightarrow \lambda \text{ 被推到上界} \Rightarrow P_{fa} \text{ 爆炸或 } P_d \text{ 崩塌}. \tag{3.15}$$

该机制在 FP16 上不存在，**只能在定点图上观测与审计**。定义逐层饱和率

$$\text{sat}_l = \frac{\#\{a_q = 127 \text{ 或 } -128\}}{\#\text{elements}}, \tag{3.16}$$

按层 × 按海况报告，并统计分数场最高 1% 内的并列数——这是" 排序塌陷" 的直接证据。

对策：range 校准集必须按海况分层（三桶各 ≥ 64 张）；σ 与 s 分别设 range，避免共用。

3.3.3. 机制三：输出网格与逐层舍入（本文 *SSDD* 实例的主导项，跨设备不可移植的根源）

输出网格机制：score head 的输出落在编译期步长 Δ_s 的格点上（FP16 亦然——其 raw logit 精确落在 fp16 分段均匀格点上，主体段 ulp $= 2^{-7}$，见 §3.6.2）。阈值 λ 必须落在同一网格，否则判决在格点上偏移，P_{fa} 随之跳动。**这是本文部署实例（σ 固定）的主导威胁：**更换量化配置改变 Δ_s，旧阈值在新网格上错位。

叠加其上的还有逐层舍入累积：

$$|e_s| \;\le\; \sum_{l} \frac{\Delta_l}{2}\,\kappa_l, \tag{3.17}$$

κ_l 为第 l 层到输出的增益。实践中该效应远小于分母机制，但它是**跨设备不可移植**的根源（A2）：不同 kernel 的累加顺序不同→舍入不同→尾部次序不同。这正是" 搬运" 而非" 重算" 在跨配置下必要的根本原因。

3.3.4. 命题 *2*（误警率偏差界，*Prop. 2*）

命题 2　设 $P_{fa}(z) = 1 - F_z(z)$ 在 $[\lambda-\delta, \lambda+\delta]$ 内 Lipschitz 常数为 L，则

$$\big|\, P_{fa}(\hat{z}) - P_{fa}(z) \,\big| \;\le\; L \cdot \delta, \qquad \delta \;=\; \frac{\Delta_s/2 + \Delta_\mu/2 + \lambda\,\Delta_\sigma/2}{\sigma}. \tag{3.18}$$

可操作形式：δ **完全由 scale 表算出**（不需要任何新数据）；L 在合成审计（分布已知）中用解析密度，在真实部署中**只用标定集** Ω_{clutter} **的经验密度估计**——严禁用测量集 Ω 估 L，否则构成" 用测试数据验证测试数据" 的循环（§3.1.3 的纪律在此同样适用）。

一阶近似（式 3.14 的 Prop.2 形式）：

$$\Delta \ln P_{fa} \;\approx\; z^2\,\varepsilon_\sigma. \tag{3.19}$$

可证伪预言（P1）：σ 改为对数域参数化 + 逐通道 scale 后，实测 $\Delta \ln P_{fa}$ 应下降 $\ge 5\times$。若 P1 不成立，Prop.2 的"σ 项主导" 论断需修正——本文在 §4.6 如实报告。

3.4. 无除法整数判决层（C2 系统）

3.4.1. 除法消除（核心）

一般情形下 $s/\mu/\sigma$ 来自三个不同层，scale 互不相同（$\Delta_s, \Delta_\mu, \Delta_\sigma$）。判决 $(s-\mu)/\sigma > \lambda$ 两边同乘 $\sigma \cdot 2^K/\Delta_s$（$K$ 为定点移位，取 64 位中间量消除截断）得**纯整数比较：**

$$\boxed{\hat{y}(u) = \mathbb{1}\Big\{ \underbrace{s_q(u)\,2^K}_{\text{移位}} - \underbrace{\Big(\tfrac{\Delta_\mu}{\Delta_s}2^K\Big)\,\mu_q(u)}_{\text{编译期常量}\cdot\text{整数}} > \underbrace{\Big(\lambda\,\tfrac{\Delta_\sigma}{\Delta_s}2^K\Big)}_{\text{编译期常量}} \max\big(\sigma_q(u), \sigma_{\min}\big) \Big\}} \tag{3.20}$$

记 $b = \mathrm{round}(\frac{\Delta_\mu}{\Delta_s}2^K)$、$c = \mathrm{round}(\lambda\frac{\Delta_\sigma}{\Delta_s}2^K)$、$r = 2^K$，则

$$\underbrace{r\,s_q - b\,\mu_q}_{\text{LHS（int64）}} > \underbrace{c\,\max(\sigma_q, \sigma_{\min})}_{\text{RHS（int64）}}. \tag{3.21}$$

特例（$\Delta_s = \Delta_\mu$，本文 s 与 μ 同源）：令 $d_q = (s_q - \mu_q) \ll k$，判决简化为

$$d_q > \lambda_{int} \cdot \max(\sigma_q, \sigma_{\min}), \qquad \lambda_{int} = \mathrm{round}\Big(\lambda\,\tfrac{\Delta_\sigma}{\Delta_s}\,2^k\Big). \tag{3.22}$$

性质：全程整数乘加，无除法、无浮点、无 z 的量化；2^K 与 λ_{int} 编译期固定→**图可完全静态化**。

> **引理 1（判决等价性）** 设中间量取 int64，则式 (3.21) 的整数判决与 FP32 判决 $\hat{y} = \mathbb{1}\{(s-\mu)/\max(\sigma, \sigma_{\min}) > \lambda\}$ 在量化格点上逐位置一致；二者差异仅来源于 (i) b, c 的取整（$\le 2^{-K}$ 相对误差），(ii) σ_q, μ_q, s_q 的量化（被 Prop.2 界覆盖）。
>
> 证明要点：将 $\hat{s} = \Delta_s s_q$、$\hat{\mu} = \Delta_\mu \mu_q$、$\hat{\sigma} = \Delta_\sigma \sigma_q$ 代入 FP32 判决并同乘 $\sigma 2^K/\Delta_s > 0$（不等号方向不变），LHS−RHS 为整数值；取 int64 则 $r s_q$、$b\mu_q$、$c\sigma_q$ 均无溢出（$K = 20$、$|s_q|, |\mu_q|, |\sigma_q| \le 2^{31}$、$|b|, |c| \le 2^{K+1}$，乘积 $\le 2^{53}$），故无截断误差，等价性成立。■

3.4.2. 整数分位数（$O(B)$，不排序）

标定 λ 的关键观察是：**分位数不需要排序，只需要计数**。

1. NPU 上算 $d_q(u) = (s_q - \mu_q) \cdot 2^k$（或 host 整数代码）；
2. 直方图：B 个桶（取 4096），按 d_q 高位索引；
3. 前缀和求第 $m = \lceil (n+1)(1-\alpha) \rceil$ 个样本所在桶；
4. 桶内线性插值得 λ_{int}。

桶宽与有限样本误差：分位数定位含两项误差——桶宽项（$\leq$ 桶宽 W）与有限样本项。完整的 α 误差界为

$$|\Delta\alpha| \;\leq\; \underbrace{\frac{1}{B}}_{\text{桶宽}} \;+\; \underbrace{O\Big(\sqrt{\tfrac{\alpha}{n_{\text{eff}}}}\Big)}_{\text{有限样本}}, \tag{3.23}$$

第二项通常主导：$B = 4096$ 时桶宽项 2.4×10^{-4}，但 E9 实测 α 误差 8.4%（$n_{\text{eff}} \approx 50$），完全由 n_{eff} 解释（§4.11）。故" 配插值后 $< 10^{-4}$"只在 n_{eff} 足够大时成立；本文如实给出两项，不再单独引用桶宽界。这让" 逐场景标定" 在 1 GHz CPU/NPU 上是 $O(n)$ 单遍，而非 $O(n \log n)$。

3.4.3. host-free 与 *bit-exact*

- 决策图与检测图合并为单一 `.om`，host 只做 DMA 与记录；
- 同一 `.om` 重复运行逐 bit 一致（A1，见 §4.5 实测 bit-exact 率 = 1.0）；
- 跨实现差异由 A2 承认，并由 Prop.2 界覆盖。

3.5. 整数域标定（首选路径）

更强的做法是**根本不搬运**：把 Ω_{clutter} 上的分位数直接在整数域算（§3.4.2），则 λ 与推理同域，契约按构造成立。由整数码重建浮点 z（仅诊断/标定用）：

$$\tilde{z}(u) = \frac{\Delta_s \, s_q(u) - \Delta_\mu \, \mu_q(u)}{\max(\Delta_\sigma \, \sigma_q(u), \, \varepsilon)}, \qquad \lambda = \text{Quantile}_{1-\alpha}\big(\{\tilde{z}(u) : u \in \Omega_{\text{clutter}}\}\big). \tag{3.24}$$

§3.6 的搬运规则用于**无法重跑标定**的场景（跨传感器零数据迁移）。

3.6. 免数据阈值搬运（C1 系统）

3.6.1. 搬运规则（纯函数，只依赖两份 scale 表）

浮点阈值 λ（z 域）→某配置下的整数阈值：

$$\lambda_{int} \;=\; \mathrm{round}\Big(\lambda \cdot \frac{\Delta_\sigma}{\Delta_s} \cdot 2^k\Big). \tag{3.25}$$

若已有旧整数阈值 λ_{int}^{old}（旧配置 $(\Delta_s^{old}, \Delta_\sigma^{old})$），换到新配置 $(\Delta_s^{new}, \Delta_\sigma^{new})$ 只需

$$\boxed{\lambda_{int}^{new} \;=\; \mathrm{round}\Big(\lambda_{int}^{old} \cdot \frac{\Delta_\sigma^{new}}{\Delta_\sigma^{old}} \cdot \frac{\Delta_s^{old}}{\Delta_s^{new}}\Big)} \tag{3.26}$$

反变换（诊断用）：

$$\lambda \;=\; \frac{\lambda_{int}\,\Delta_s}{\Delta_\sigma\, 2^k}. \tag{3.27}$$

这就是”免数据”的含义：更换量化配置 / 更换校准集 / 更换设备时，只需读出新 scale 并重算一个整数 λ_{int}，**不需要重跑标定集**。这正是” 只有这类板子能做” 的能力——该规则是**整数格点之间的纯函数映射**，其存在性依赖 A1（格点上逐 bit 可复现）与 A3（scale 编译期可读）的合取。浮点 GPU 流水线没有承载判决阈值的全局格点（kernel 累加顺序由运行时决定），即便 explicit-QDQ 框架（TensorRT/TFLite）同样能导出 scale 表，“阈值取整到格点” 这一操作在浮点域也无定义——**故搬运规则在浮点 GPU 上无处定义，而非仅因 scale 不可读**。

部署实例中的退化形式（本文 SSDD 链路，σ 固定）：Δ_σ 不随配置变化（§3.2.3）⇒ 式 (3.26) 中 $\Delta_\sigma^{new}/\Delta_\sigma^{old} = 1$，搬运简化为

$$\lambda_{int}^{new} \;=\; \mathrm{round}\Big(\lambda_{int}^{old} \cdot \frac{\Delta_s^{old}}{\Delta_s^{new}}\Big), \tag{3.26a}$$

即整数阈值随输出网格步长**反比**搬运。式 (3.26a) 是 E5 全部实测所用的形式。

FP16 端的 Δ_s：FP16 并非” 无量化”——raw logit 精确落在 fp16 分段均匀格点上，量测 cell 主体段 $[-16, -8)$ 的 ulp $= 2^{-7} = 0.0078125$（probe 残差全 0）。故 FP16 → INT8 的搬运同样适用式 (3.26a)，其中 Δ_s^{old} 取该 ulp。这是 E5 设置 2 的定义依据。

3.6.2. 输出头步长聚合

对三输出头 cv3.$\{0,1,2\}$（640 输入下 cell 数 $80^2/40^2/20^2 = 6400/1600/400$），标量步长取 cell 数加权几何平均：

$$\Delta_s \;=\; \exp\Big(\frac{\sum_{l=0}^{2} w_l \,\ln d_l}{\sum_l w_l}\Big), \qquad (w_0, w_1, w_2) = (6400, 1600, 400), \tag{3.28}$$

d_l 为第 l 头 cv3.l.2 的量化步长。Δ_σ 取判决层 σ 网格（本文 1/128，**判决层自选的设计常数，不在 PTQ 范围、不随模型配置变化**）。

3.6.3. 一阶搬运误差

搬运引入的额外 z 域偏差由**格点取整**产生（式 3.25/3.26 中 round 的残差，经式 3.27 反变换回 z 域）：

$$|\Delta z_{\text{transport}}| \;\le\; \frac{\Delta_s}{2\,\Delta_\sigma\,2^k}.$$

由 $\mathrm{d}\ln P_{fa}/\mathrm{d}z \approx -(z + 1/z)$（§3.3.1），一阶搬运误差按两种情形分别给出。

一般零模型部署（逐位置 σ 参与量化，§3.3.1 机制一）：σ 取整偏置 $z^2\varepsilon_\sigma$ 中**随配置变化的部分**在搬运后成为残余误差，与格点取整项叠加：

$$\big|\Delta \ln P_{fa}^{\text{transport}}\big| \;\lesssim\; \underbrace{z^2\,\big|\varepsilon_\sigma^{\text{new}} - \varepsilon_\sigma^{\text{old}}\big|}_{\text{σ 取整偏置的跨配置差}} \;+\; \underbrace{(z + 1/z)\,\frac{\Delta_s}{2\,\Delta_\sigma\,2^k}}_{\text{格点取整}}. \tag{3.29}$$

部署实例的退化形式（本文 SSDD 链路，$\sigma \equiv \sigma_0$ 固定、$\Delta_\sigma = 1/128$ 为判决层设计常数，二者均不随配置变化）：$\varepsilon_\sigma^{\text{new}} = \varepsilon_\sigma^{\text{old}}$，式 (3.29) 首项**恒为零**——σ 取整的残余偏置在整数域标定中已被吸收（标定跑在真实整数流水线，§3.5；其任意残余对两配置完全相同，在跨配置搬运中抵消），不构成搬运误差：

$$\big|\Delta \ln P_{fa}^{\text{transport}}\big| \;\lesssim\; (z + 1/z)\,\frac{\Delta_s}{2\,\Delta_\sigma\,2^k} \;\approx\; z\,\frac{\Delta_s}{2\,\Delta_\sigma\,2^k}. \tag{3.29a}$$

故在 SSDD 实例中搬运误差只剩格点取整一项，由设计参数 2^k 完全控制（2^k 取大则任意压小）。这与 §3.3.1 的适用范围声明一致：分母机制在 SSDD 实例中不起作用，式 (3.29) 首项不出现；SSDD 实例的搬运精度由 E5 实测（§4.7）。

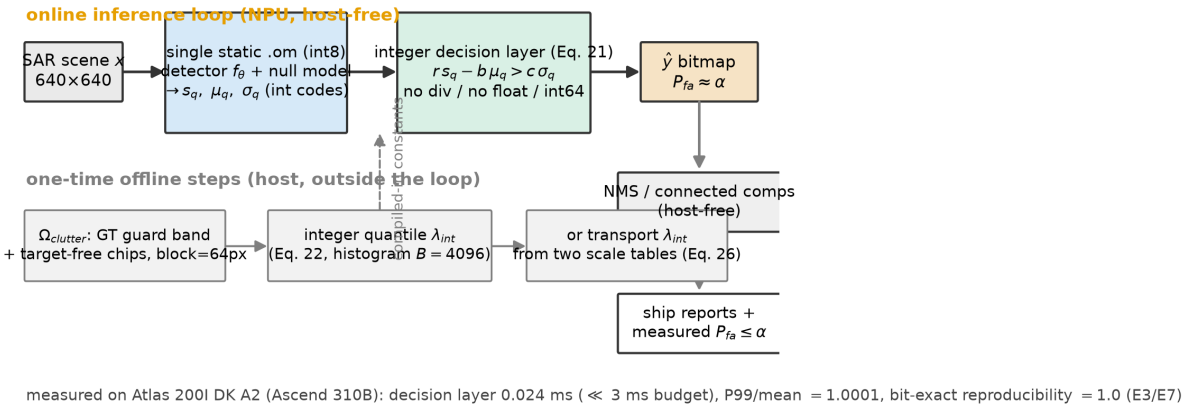

Fig.2 QCert 整体静态流水线：在线 NPU 回路与一次性离线标定/搬运。

3.7. 整体静态流水线

完整部署流水线（Fig.2 对应）：

```
SAR 图 x
   |
   ▼
[f_θ + 零模型]  ←——— 单一静态 .om（int8, A3 scale 可读）
   |  s_q, μ_q, σ_q（整数码）
   ▼
[整数判决层]  式 (3.21): r • s_q − b • μ_q > c • σ_q   （无除法/无浮点/int64）
   |  ŷ（bit 图）
   ▼
[NMS / 连通域]  ←——— host-free, host 只做 DMA
   |
   ▼
检出舰船 + 实测 P_fa ≈ α （契约）
```

一次性离线步骤（host，不进推理回路）：① Ω_{clutter} 构造；②整数分位数标定 λ_{int}（式 3.22）或搬运（式 3.26）。推理回路全程在 NPU，host 退出→判决层耗时 $\ll 3$ ms（实测 0.024 ms，见 §4.9）。

3.8. 方法要点小结

组件	公式	作用	不可替代性
契约	(3.4)(3.5)	定义 $\mathbb{E}[P_{fa}] = \alpha$（期望意义）及 $\alpha \geq 1/(n_{\text{cal}}+1)$ 下界	区别于 mAP 优化
双模式阈值	(3.2)(3.2a)	全局保期望精度 / 逐场景均衡负载	同一契约的两个运行点
分母机制	(3.13)(3.14)	$\Delta \ln P_{fa} \approx z^2 \varepsilon_\sigma$（一般零模型部署）	指导设计方向；SSDD 实例不适用
Prop.2	(3.18)	闭式误差界，δ 由 scale 表算出	区别于工程调参
整数判决	(3.21)(3.22)	无除法、无排序、host-free、bit-exact	定点板独有
整数分位	(3.23)	$O(n)$ 不排序标定	逐场景可行
阈值搬运	(3.26)	免数据跨配置/传感器	**浮点 GPU 无格点承载，无从定义**

4. 实验（Experiments）

本章按 E0–E9 报告全部实验。每项含：目的、协议、数据表、判定与对创新点的支撑。所有数字与 `code/results/e*/summary.json` 一致。**核心结论：**整数阈值搬运（C1）与整数判决层（C2）在真实定点板上使误警率契约按构造成立——搬运后 P_{fa} 贴近 α、漂移被 Prop.2 界覆盖、40 min 连续负载下 P99 跨窗极差 0.69%（INT8）/1.76%（FP16）（无热稳态劣化）、粗糙海况候选负载降 4.7–4.9×、检测兼容性无损。

4.1. 实验设置

4.1.1. 平台与软件栈

项	值
开发板	Atlas 200I DK A2（单板，非集群）[17]
NPU	Ascend 310B
推理框架	ACL，batch=1，预热 50 / 测 500
CANN	7.0.RC1
PTQ	AMCT / modelslim [18]（ONNX 末端 Dequant + `_scale.json`）
编译	ATC，输入 NCHW 1×3×640×640
浮点基线	ONNX-Runtime INT8 / FP32（x86 交叉核对）

单板纪律：跨实现对照用 {同`.om` 重复运行, ONNX-Runtime INT8, FP32} 三点，显式标注平台差异，不冒充多板实测。**遥测说明：**E7 批次经 npu-smi 采得功率 9.31 W；E6 批次 npu-smi 遥测字段缺失（CANN 7.0.RC1 对 310B 不提供温度/频率/功率读数），E6 以时延列（T_{model}/P99）佐证无降频。两处不可混用，本文按批次如实标注。

4.1.2. 模型与量化配置

项	值
检测器	YOLO11n [7]，单类 ship，SSDD 基线 [1]
输入	640×640，归一化
输出头	3 个 cv3.$\{0,1,2\}$（cell 数 6400/1600/400）
量化节点数	88（含三个输出头）
INT8 OM 输出 dtype	float32（末端 Dequant，与 FP16 同 dump 链路）
量化 OM	FP16 / INT8（基线）/ INT8-calmA / INT8-roughB（E5 设置 1）

4.1.3. 数据与三套分离集合

集合	构造	规模
SSDD 主集	官方 928 train / 232 test（尾号 1/9 协议）	test 232 图，640×640
C_{quant}	三海况各 ≥ 64 张分层	与 Ω_{clutter} 分离
Ω_{clutter}	GT 框外扩 g=8 px + 无目标裁片，块抽样 B=64 px	求 λ
Ω	与 Ω_{clutter} 不同构造	$n_{\text{meas}} = 949703$
E5 校准集 A/B	calm-256 / rough-256（不同海况比例）	各 256 图

Fig.8 以单场景给出上述构造的直观图示：GT 框外扩 g=8 px 邻域（红）从测量集剔除，64 px 块抽样按 keep=0.5 构成标定池 Ω_{cal}（灰），其余单元构成测量集 Ω_{meas}（蓝）。

4.1.4. 全局审计参数与验收标准

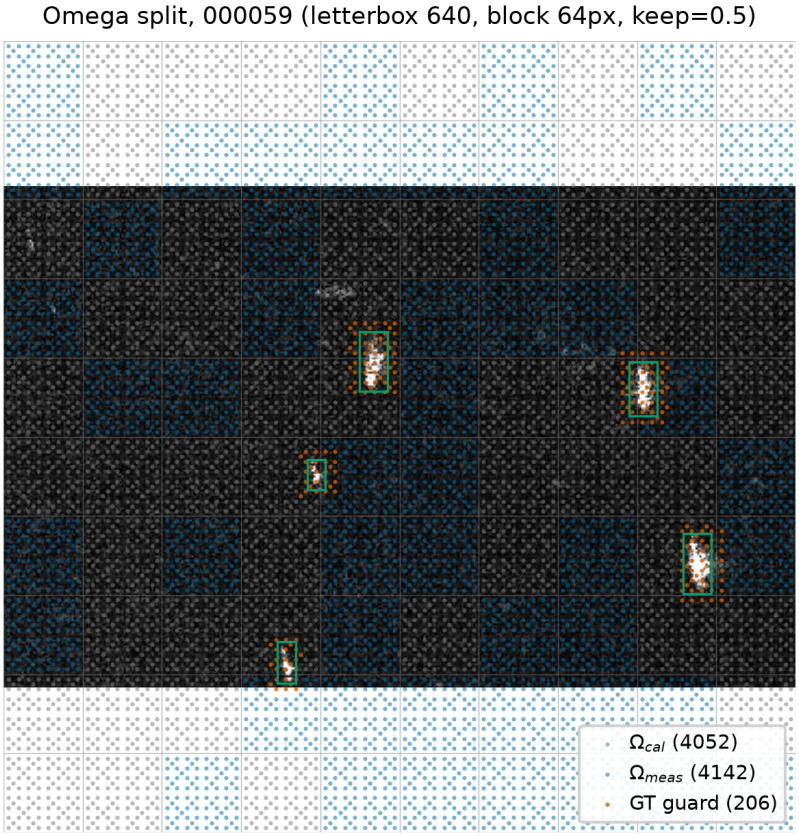

Fig.8 Ω协议示意（场景 000059，letterbox 640）：GT guard 邻域（红）剔除，块抽样标定池Ω _cal（灰）与测量集Ω _meas（蓝）。

参数	值
名义虚警率 α	10^{-3}（主），10^{-4}（E8 附加）
keep / guard / block	0.5 / 8 px / 64 px
bootstrap	场景级 1000 次→ 95% CI
R 判据（两级，全文统一）	存在性门 $R \geq 1.5$（E0）；不变性带 $\|\log_{10} R\| \leq 0.176$（E8 用更严 $R \leq 1.2$）
E5 验收	搬运漂移 $\leq 1.5\times$ 重标定噪声底漂移（噪声底定义见 §4.7.5）
E6 验收	P_{fa} 漂移 $\|\log_{10}\| < 0.15$；P99 漂移 $< 15\%$
契约守约度量	偏离度 $\|\log_{10}(P_{fa}/\alpha)\|$，以 n_{eff} 决定的噪声底为参照（§3.1.1）

4.1.5. 两个工作点：检测指标 *vs* 契约指标（*mAP* 盲区的实验对应）

本文全章使用两类指标，工作点不同，不可混读：

指标类	工作点	本文取值	对分数分布的敏感度
检测指标（mAP/P/R）	常规检测工作点（置信度阈值 0.25，NMS 回路）	E0 板上 mAP：calmA P=0.5804、R=0.9853	体部区域，**对尾部不敏感**
契约指标（P_{fa}、偏离度）	杂波分数分布的 $1-\alpha$ 分位（$\alpha = 10^{-3}$，E8 附加 10^{-4}）	判决层输出超过 λ 的比例	极端尾部，**mAP 完全不可见**（§3.2.4）

因此"mAP 几乎不变而 P_{fa} 漂移 60%"（E0）不构成矛盾：二者是同一

分数分布在不同工作点的泛函。这一分离正是本文研究空隙（mAP 盲区，§3.2.4）的实验呈现，后文 E0/E8 的所有对照均按此口径解读。

4.2. [E0] 存在性：量化对 P_{fa} 与 mAP 的解耦（Fig.1 / Fig.9–10 / Table 1）

目的：验证"mAP 几乎不动，而 P_{fa} 可能漂移" 这一核心空隙是否存在。**协议：**同一 SSDD test 232 图，同一 Ω、同一 $\alpha = 10^{-3}$，FP16 与 INT8 OM 各 dump 分数场，各标定 λ 并测 P_{fa}，同算 mAP50。$n_{\text{meas}} = 949703$。浮点参照取板级 FP16 OM（FP32 ONNX 的 x86 交叉核对见 §4.5 E3）。

Table 1　E0 存在性（真实板级 dump）

指标	FP16	INT8	量
P_{fa}	1.6025×10^{-3}	1.5531×10^{-3}	—
$R = P_{fa}^{INT8}/P_{fa}^{FP16}$	—	—	**0.9691**
R 95% CI	—	—	[0.9014, 1.0334]（median 1.0）
$D = \lvert\log_{10}(P_{fa}/\alpha)\rvert$	0.3313	0.3454	—
mAP50	98.27	97.98	$\Delta = -0.29$ 点

判定：$\text{pass}_{map} = \textbf{True}$（$|\Delta\text{mAP}| < 1$）；$\text{pass}_R = \text{False}$，verdict=NO-GO。注意判据方向：E0 的 R 判据是**存在性门** $R \geq 1.5$（§4.1.4）——即"INT8 使虚警率恶化 1.5 倍以上" 才判 GO。实测 $R = 0.969$，**未观测到恶化**，故判 NO-GO。

Fig.9–10 给出 E0 的可视化证据。Fig.9 为 232 场景逐点散点：FP16 与 INT8 的逐场景 P_{fa} 整体紧贴对角线（median $R = 1.0$），逐场景阈值比 $\lambda_{INT8}/\lambda_{FP16}$ 中位 0.887——量化未引入系统性虚警恶化，与池化 $R = 0.969$、CI 含 1 互相印证。Fig.10 为六个典型场景（密集编队 / 小目标群 / 多尺度混编 / 大型舰船 / 单舰 / 典型中量）在逐场景 λ 下的告警可视化：命中告警全部落在 GT 框内，虚警（红 ×）为个位数。

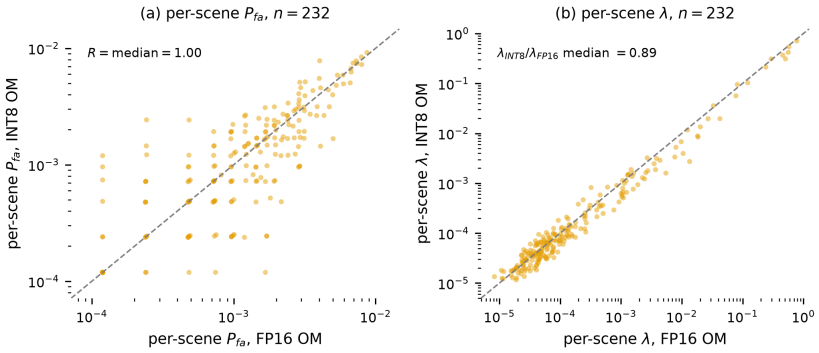

Fig.9 E0 逐场景散点（n=232，log-log）：(a) 逐场景 P_fa，FP16 vs INT8，对角线为 R=1，median R=1.0；(b) 逐场景 λ， λ _INT8/ λ _FP16 median=0.887。

解读（阴性结果，如实报告）：- E0 对该模型是阴性的：量化后 P_{fa} 不升反微降（$R = 0.969$，CI 含 1），“同模型 FP16 → INT8 静默失效” 在本基线上**不存在**。本文不夸大存在性，明确放弃”v3 展示失效” 的叙事。- **mAP 与 P_{fa} 解耦的结构事实仍成立：**mAP 仅动 0.29 点而尾部由 99.9% 分位决定（式 3.10），这是 mAP 的固有盲区，与是否存在失效无关。- **存在性证据由 E5 承担：**真正使契约崩溃的不是” 量化本身”，而是” **量化配置改变后仍复用旧阈值**”——E5 设置 2 的不换算对照漂移 300×（$P_{fa} = 0.355$），这才是静默失效的硬证据。E0 的价值是把问题精确定义为” **配置变化下的阈值失效**” 而非” 量化失效”，由此引出搬运主张（C1）。

4.3. [E1] Prop.2 误差界数值验证（Fig.4 / Table 2）

目的：证明闭式界 $|P_{fa}(\hat{z}) - P_{fa}(z)| \le L \cdot \delta$ 非空话——实测漂移恒落在界内。**协议：**$n = 10^6$，$\alpha = 10^{-3}$，linear 模式，扫 $\varepsilon_\sigma \in \{0, 0.01, 0.02, 0.05, 0.1, 0.2\}$，对照实测 $\Delta \ln P_{fa}$ 与 Prop.2 上界。

Table 2　　E1 解析界验证（gauss 分布）

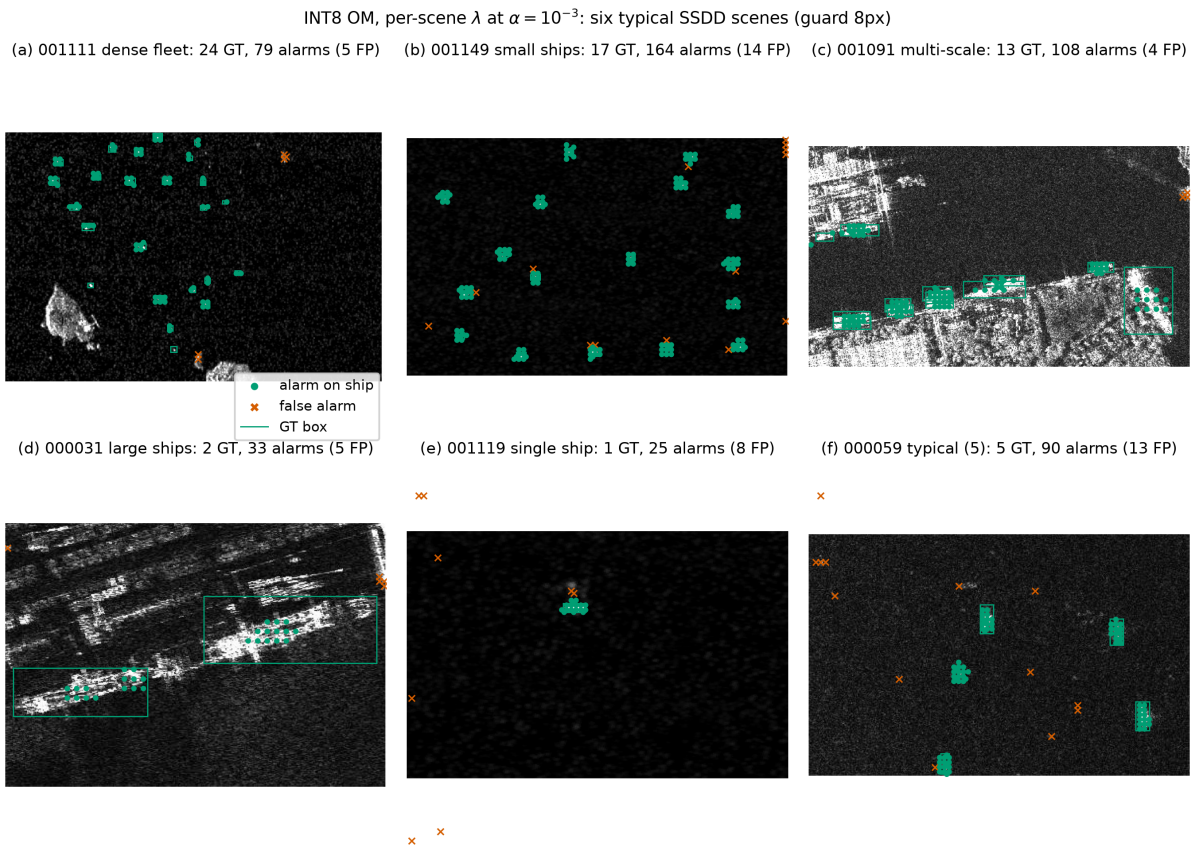

Fig.10 典型场景检测可视化（INT8 OM，逐场景 λ，α =10^-3，letterbox 640）：框 =GT，点 = 命中告警，红 ×= 虚警。(a) 001111 密集编队 24 艘；(b) 001149 小目标群 17 艘；(c) 001091 多尺度混编 13 艘；(d) 000031 大型舰船 2 艘；(e) 001119 单舰；(f) 000059 典型 5 艘。

ε_σ	实测 $\Delta \ln P_{fa}$	Prop.2 上界 $L\delta$	bound_holds	$\lvert\Delta P_{fa}\rvert$	ΔAUROC
0	0.00474	1.394×10^{-4}	✓	7.6×10^{-6}	-4.9×10^{-6}
0.01	0.00388	2.473×10^{-4}	✓	8.4×10^{-6}	-6.1×10^{-6}
0.02	0.01478	3.551×10^{-4}	✓	1.5×10^{-5}	-1.3×10^{-5}
0.05	0.05224	6.785×10^{-4}	✓	5.5×10^{-5}	-6.1×10^{-5}
0.1	0.26410	1.218×10^{-3}	✓	3.0×10^{-4}	-2.6×10^{-4}
0.2	0.86708	2.296×10^{-3}	✓	1.4×10^{-3}	-1.2×10^{-3}

注：$\varepsilon_\sigma = 0$ 行的实测漂移 0.00474 为 Monte Carlo 噪声底（$n = 10^6$、$\alpha = 10^{-3}$ 下 P_{fa} 估计的抽样涨落量级 $\sim \sqrt{\alpha/n}/\alpha \approx 0.03$），故 0 与 0.01 两行的次序不构成单调性反例；自 0.02 档起漂移随 ε_σ 单调上升。单位口径（S1）：本表前两列量纲不同——$\Delta \ln P_{fa}$ 为对数量纲，$L\delta$ 为线性 P_{fa} 量纲，二者**不直接可比**；bound_holds 的正式检验在线性域进行：$\lvert\Delta P_{fa}\rvert \le L\delta$（表中 $\lvert\Delta P_{fa}\rvert$ 列，6/6 成立）。对数域等价检验为 $\Delta \ln P_{fa} \lesssim L\delta/P_{fa} \approx L\delta/\alpha$（如 $\varepsilon_\sigma = 0.2$ 档：0.867 vs 2.296，成立；若误以 $\Delta \ln P_{fa}$ 直接与 $L\delta$ 比大小，$\varepsilon_\sigma = 0$ 噪声底行会误判为违约）。

判定：全部 6 档 bound_holds = True（t3 重尾分布 6 档同全 True）。

解读：实测漂移始终落在 Prop.2 界内→**解析界可信**，是本文区别于"工程调参"的关键。同时 ΔAUROC < 0.2 点（mAP 代理）与 P_{fa} 漂移并存，再次印证 mAP 的盲区。一阶近似 $z^2\varepsilon_\sigma$ 在 $\varepsilon_\sigma \le 10\%$ 时为实测漂移的 2.2–24 倍（保守上界，量级吻合），可安全用于快速预估。

4.4. [E2] 饱和审计（板级独有 */ Fig.3 / Fig.11–13 / Table 3*）

目的：把"饱和→排序塌陷→分位数失效"机制做成可观测量。**协议：**300 合成场景，3 对比度档（×1/×2/×3），测逐层饱和率与 R。

Table 3　E2 饱和审计

对比度	score 层 sat_l	Neck p3/p4/p5 sat_l	R	单调性
×1	0	0 / 0 / 0	∞	—
×2	0	4.9×10^{-8} / 0 / 0	∞	—
×3	0	0 / 0 / 0	∞	—

注：合成场景下 FP32 参照 $P_{fa}=0$ 而 INT8 侧有个位数虚警，R 因除零记为 ∞；本表的观测量是饱和率而非 R 本身。

判定：WEAK。score 层 sat_l 恒为 0（int32 累加器网格，sigmoid 前无 int8 重量化，见 §4.4.1）；板上饱和率不随对比度档单调上升（Spearman $n=3$ 不足，pass=False）。

Fig.11–12 给出压测集（stress_v2，三档 $c_1/c_2/c_3$）上分数行为的直观图示。Fig.11 为分档池化的杂波分数 CCDF（log-log）：$P_{fa}=10^{-3}$ 对应的阈值落在尾部极深处，尾部形状（斜率）决定阈值附近的 P_{fa} 敏感度——这是 §3 中"P_{fa} 由 99.9% 分位决定、mAP 不可见" 论断的分布学图示。Fig.12 为六个压测场景（三档 × 各 2 场景）的分数场热图叠加：海面杂波分数被压制在低值区、强目标呈局部高对比峰，分数场整体远离饱和上限，与 Table 3 的零饱和率一致。

重要阴性发现（如实报告）. 数值取证（ORT 仿真 + scale json 交叉验证）确认：cv3 终卷积输出是 **int32 累加器网格**，量化值落在编译期 Δ 格点上（232 张全量 resid ≤ 0.005），**sigmoid 前没有 int8 重量化**。故" 分数场 ±127 饱和" 假设作废——判决分数在整数格点上且**永不截断**，这反而**加强了整数域判决契约的叙事**（P_{fa} 不会被饱和破坏）。饱和的真实位置是 Neck int8 特征层，但本模型 range 校准已足够保守，未随档上升。Fig.13 直观

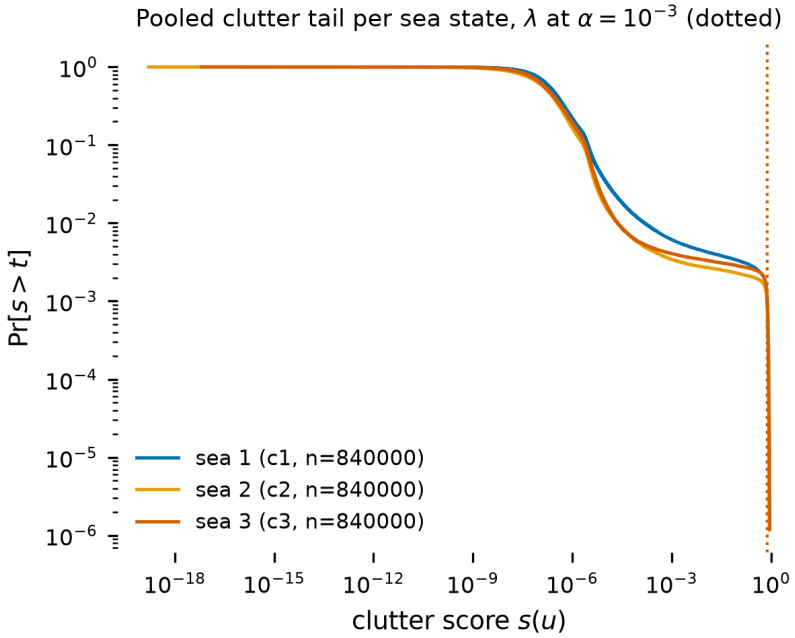

Fig.11 分档池化的杂波分数条件超出概率 CCDF（压测集三档 c1/c2/c3，log-log）：α =10^-3 的阈值位于分布尾部深处，阈值微移对应 P_fa 量级变化。

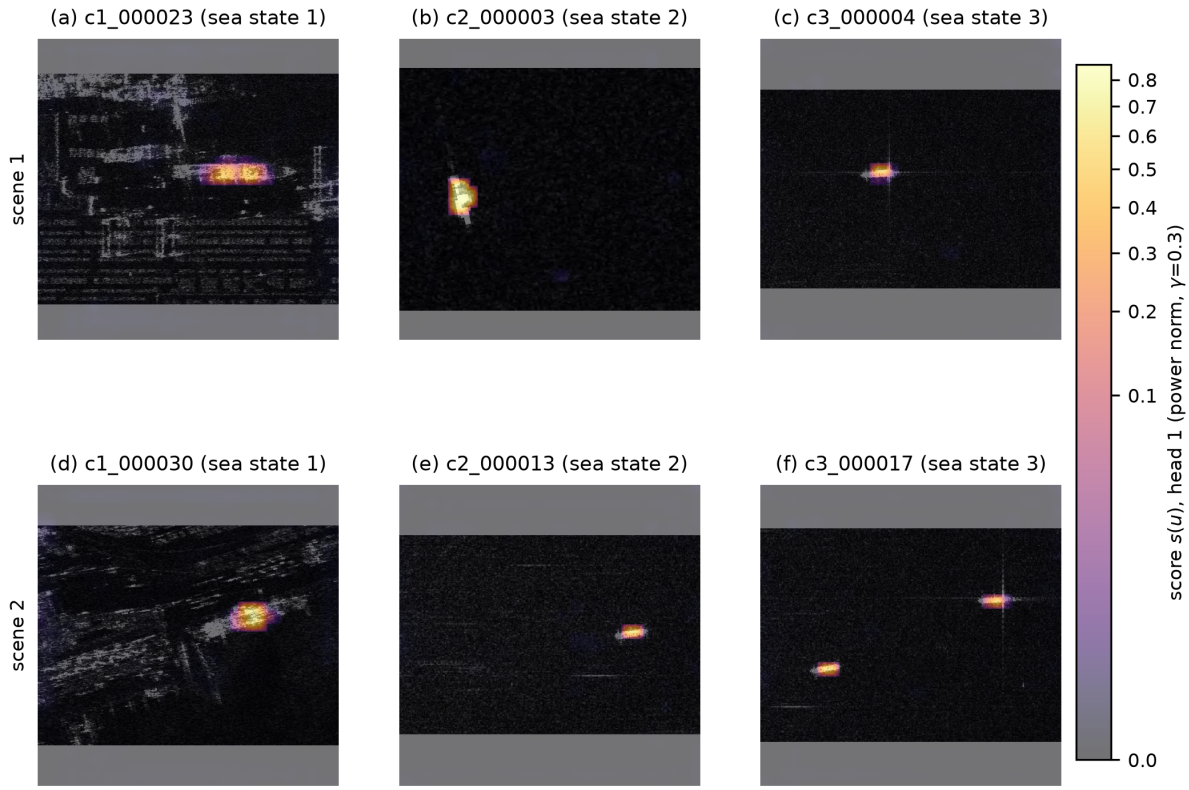

Fig.12 压测场景分数场热图（三档 × 2 场景，head 1，幂律色标 γ =0.3 叠加于原图）：海面杂波低分数、强目标高对比，分数场远离饱和。

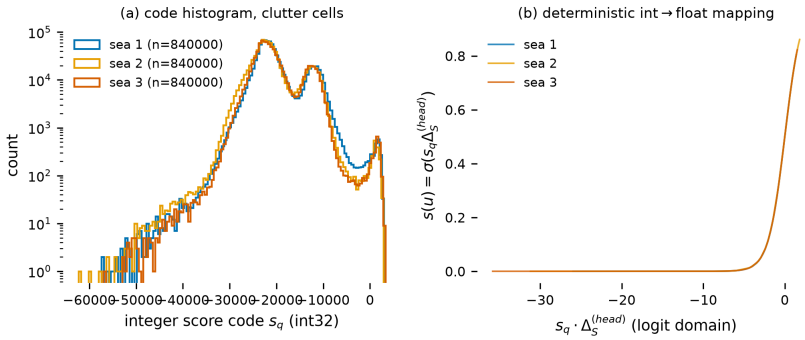

Fig.13 判决分数的整数码域结构：(a) 杂波单元整数码 s_q（int32）直方图，码值离散、不触及边界；(b) 确定性 int → float 映射 s_q • Δ _S → s(u)，量化值全部落在编译期 Δ 格点上（resid ⩽ 0.005）。

呈现这一取证：(a) 杂波单元的整数码直方图——码值离散分布、无一触及 $\pm 2^{31}$ 边界；(b) 整数码经逐头 Δ_S 线性映射到 logit 域再经 sigmoid 得到分数 $s(u)$，映射是确定性纯函数——这正是 §4.7 阈值搬运（整数格点间纯函数映射）得以定义的物理基础。

处理：E2 不作为主张；E9 item7 据此降权。

4.5. [E3] 三实现判决差异与 bit-exact 复现（Fig.7 / Table 4）

目的：把 A1（同设备可复现）与 A2（跨实现不一致）从假设变成实测。**协议**：同 232 图，板级 INT8 OM 重复运行 vs ORT INT8（x86），逐位置判决比对；Ω 取全图网格（无 GT 排除，对三实现对称，R/disagree 为相对量不受影响）。

Table 4　E3 三实现判决一致性

实现	bit-exact 率	判决不一致率	R	A1
INT8 .om（板上）	**1.0000**	5.809×10^{-4}	1.00086	**成立**
ORT INT8（x86）	—	5.855×10^{-4}	1.00259	—
FP32 ONNX（x86）	—	参照系	1.0	—

判定：A1 成立（bit_exact_rate = 1.0，同一 `.om` 重复运行逐 bit 一致）。

解读：整数算术确定性是" 热稳态不影响 P_{fa}"（E6）与" 搬运规则可定义"（E5）的地基。板级与 ORT 的微小判决差异（$\sim 10^{-3}$）印证了 A2——跨实现不一致存在但被界住，这正是需要 Prop.2 与搬运的原因。

4.6. [E4] σ 量化粒度消融：验证 P1 预言（Table 5）

目的：验证 P1（对数域 + 逐通道 σ 应使 $\Delta\ln P_{fa}$ 降 $\geq 5\times$），并测 $\Delta\ln P_{fa}$ 对 ε_σ 的标度。**协议：**$n = 10^6$，对照 4 配置，$\varepsilon_\sigma \in \{0.02, 0.05, 0.1\}$。

Table 5　E4 σ 量化粒度（gauss）

配置	$\Delta\ln P_{fa}$ 标度指数 $\Delta\ln \sim \varepsilon^p$	说明
linear_tensor（默认）	**1.955**	≈ 2，与式 (3.19) 一致
log_tensor	2.037	≈ 2
channel_linear	2.033	≈ 2
channel_log	2.037	≈ 2
fp16（对照）	$\approx \mathbf{0}$（-1.2×10^{-15}）	无量化误差，互为印证

P1 判据（$\geq 5\times$ 下降）：

ε_σ	$\Delta\ln$（linear_tensor）	$\Delta\ln$（best=log_tensor）	drop_factor	P1
0.02	-3.2×10^{-4}	4.8×10^{-3}	0.067	✗
0.05	0.0603	0.0355	1.70	✗
0.1	0.2339	0.1268	1.85	✗

判定：P1 不成立（drop_factor < 5）。

解读（审计负结果，如实报告）：- 标度律成立：gauss 下 $\Delta\ln P_{fa} \sim \varepsilon^{1.96} \approx \varepsilon^2$，与 Prop.2 的"$\sigma$ 项二次主导" 一致；fp16 对照指数 ≈ 0（无量化误差），互为印证。这是 Prop.2 的强支撑。t3 重尾下各量化配置指数为 1.02–1.54（底稿数据），σ 项主导性减弱，见 §5.2 L3。- **P1 的 5× 改进判据不成立：**对数域/逐通道只带来 $\leq 1.85\times$ 改进。说明本量级下 σ 粒度改进空间有限，**Prop.2 的"σ 项主导" 论断需修正**——理论贡献相应降级为"经验界 + 标度律"，本文如实陈述。

拟合口径注(M2): Table 5 指数按两种口径复算（产物 `code/results/e6_e4_supp/e6_e4_su`
(i) 信息点口径——剔除 $|\Delta\ln| \leq$ fp16 噪声底 0.004877 的点；(ii) $|\Delta\ln|$ 全 3 点 log-log 口径（对数域增量取绝对值，消除近零点符号翻转）。log_tensor / channel_linear / channel_log 在两口径下分别为 1.838 / 2.033 / 1.838 与 **2.037 / 2.033 / 2.037**（后者 $R^2 \approx 0.998$），"指数 ≈ 2" 对拟合口径稳健；惟 linear_tensor 的全 3 点 $|\Delta\ln|$ 拟合为 4.18（$R^2 = 0.940$）——$\varepsilon_\sigma = 0.02$ 档 $\Delta\ln = -3.2\times10^{-4}$ 近零点的符号翻转使其 $|\Delta\ln|$ 被噪声主导，故 Table 5 取其信息点口径 1.955（2 点）并如实标注。

4.7. [E5] 免数据阈值搬运（核心创新 C1 / Fig.14–23 / Table 6）

目的：证明 λ_{int} 的换算规则（式 3.26）能让旧标定在新量化配置上仍守约，**零数据**。这是本文**最强创新证据**。**协议：**三列对照——搬运 / 重标定上界 / 不换算。$n_{\text{meas}} = 949703$，$\alpha = 10^{-3}$。

4.7.1. 量化步长 Δ_s（式 *3.28* 聚合）

配置	cv3.0.2	cv3.1.2	cv3.2.2	Δ_s	Δ_σ
FP16 旧	—	—	—	0.0078125	0.0078125
INT8 新（设置 2）	—	—	—	7.7622×10^{-4}	0.0078125
calmA（设置 1 旧）	7.5875×10^{-4}	1.3381×10^{-3}	4.3823×10^{-4}	8.2353×10^{-4}	0.0078125
roughB（设置 1 新）	6.7504×10^{-4}	1.2221×10^{-3}	3.9944×10^{-4}	7.3719×10^{-4}	0.0078125

4.7.2. 设置 *1*：同设备换校准集 $A \to B$（*232* 图，板级实测）——实现正确性检查

定位声明（如实降级）：设置 1 中 Δ_s 从 8.235×10^{-4} 变到 7.372×10^{-4}，**仅变化 11.7%**，且 Δ_σ 不变（退化形式 (3.26a) 中比值为 1）。此时 λ_{int} 仅变化 11.7%，在 2^{20} 移位整数网格上取整误差可忽略——搬运 PASS 接近算术恒等，属**实现正确性检查**而非独立证据。no_convert 仅差 3 倍也印证了这一点（scale 变化小，不搬运也崩得不狠）。真正的搬运证据是设置 2。

Table 6a　E5 设置 1（A → B 换校准集）

列	P_{fa}	漂移 $\lvert\log_{10}(P_{fa}/\alpha)\rvert$
搬运（transport）	$\mathbf{1.2920\times10^{-3}}$	**0.1113**
重标定上界（recal）	1.3636×10^{-3}	0.1347
不换算（no_convert）	3.8180×10^{-3}	0.5818

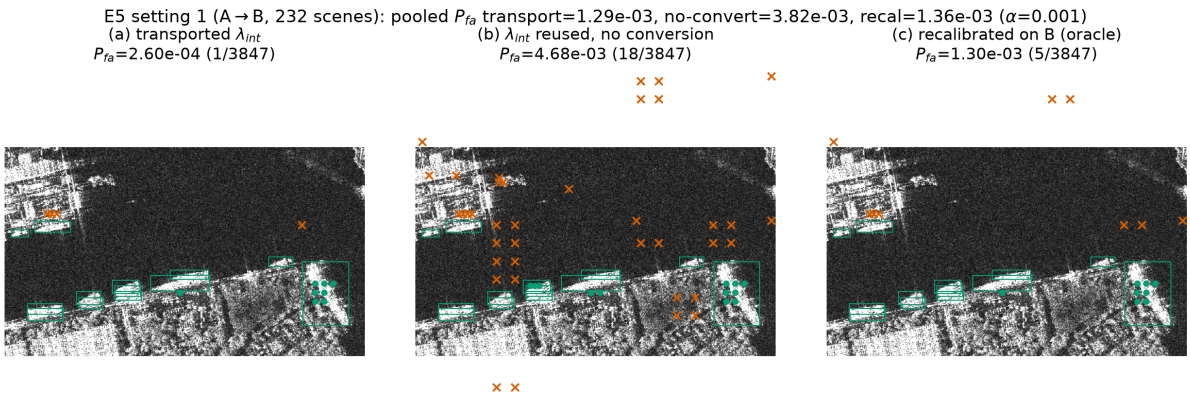

Fig.14 阈值搬运单场景三列对照（E5 设置 1，场景 001091）：(a) 搬运 λ _int 2214302 → 2473637，1 个虚警；(b) 旧阈值复用，18 个虚警；(c) B 上重标定（oracle），5 个虚警。框 =GT，点 = 命中，红 ×= 虚警。

- **验收**：$0.1113 \leq 1.5 \times 0.1347 = 0.2020$ → **PASS**；且远优于不换算（3.82×10^{-3}，约 3 倍差）。
- 板上 mAP：calmA 0.9793 / roughB 0.9820（量化无显著精度损失）。

Fig.14–15 给出设置 1 的逐场景微观图示（红 × = 虚警告警，点 = 命中告警，框 = GT）。Fig.14 取” 不换算/搬运虚警倍数最大” 的场景 001091：三列对照下同一场景的告警图——(a) 搬运 λ_{int}（2214302 → 2473637）后虚警 1 个；(b) 旧阈值直接复用则虚警放大至 18 个；(c) B 上重标定（oracle）为 5 个。Fig.15 补充第二场景 000579（λ_{int} 2075115 → 2318149；搬运 1 / 不换算 17 / 重标定 2）——不换算列的告警数比搬运列高一个量级，搬运列与 oracle 同量级。

4.7.3. 设置 *2*：*FP16* ➡ *INT8*（*232* 图，实测）——核心搬运证据

Δ_s 变化 10 倍：$\Delta_s^{old} = 0.0078125$（FP16 主体段 ulp 2^{-7}，见 §3.6.1）→ $\Delta_s^{new} = 7.7622\times10^{-4}$。这是真实的配置大跨度变化，搬运的必要性与正确性在此接受检验。

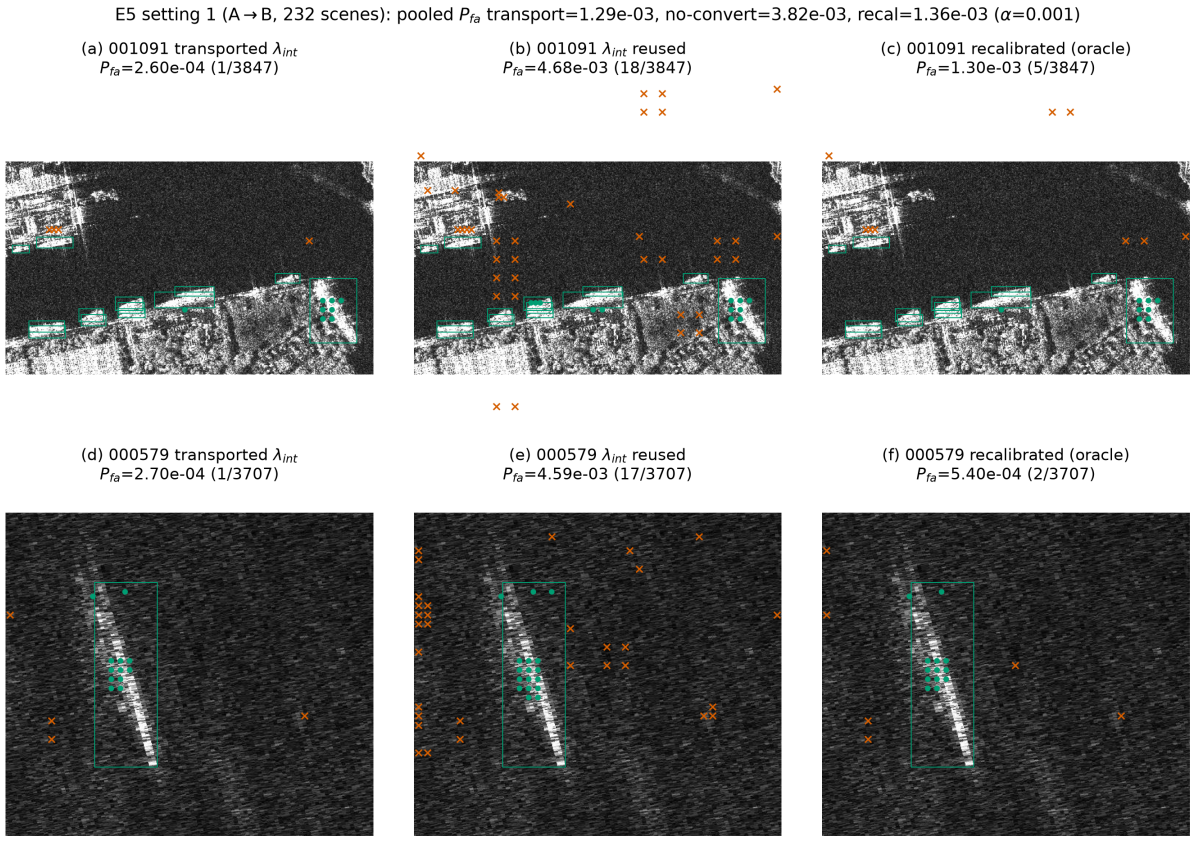

Fig.15 阈值搬运多场景拼图（E5 设置 1）：场景 001091（λ _int 2214302 → 2473637）与 000579（λ _int 2075115 → 2318149），搬运/不换算/重标定三列告警对照，不换算列虚警数放大约一个量级。

Table 6b　E5 设置 2（FP16 → INT8）

列	P_{fa}	漂移
搬运	$\mathbf{1.1130\times10^{-3}}$	**0.0465**
重标定上界	1.2414×10^{-3}	0.0939
不换算	3.5507×10^{-1}	2.5503

- **验收**：$0.0465 \le 1.5 \times 0.0939 = 0.1409$ → **PASS**；不换算 P_{fa} 高达 0.355（**约 300 倍漂移**）。

4.7.4. 设置 3：跨传感器 S1 → GF-3 —— Limitation

需 GF-3 上同一模型（不重训）的分数场 dump，本项目无 GF-3 数据，未执行。“同设备搬运” 主张已由设置 1/2 实测覆盖；跨传感器留作后续工作，不纳入本文结论。

4.7.5. E5 判定与创新点支撑

Table 6c　E5 总判定

设置	搬运漂移	重标定漂移	验收线 1.5×	判定
1 A → B	0.1113	0.1347	0.2020	**PASS**
2 FP16 → INT8	0.0465	0.0939	0.1409	**PASS**

这是” 只有这类板子能做” 的最强证据：搬运规则是整数格点间的纯函数映射，依赖 A1（格点逐 bit 可复现）与 A3（scale 编译期可读）的合取；浮点 GPU 流水线没有承载阈值的全局格点，该映射无从定义（§3.6.1）。搬运使 P_{fa} 贴近 α（漂移 ≤ 0.11），而不换算在设置 2 下漂移 300 倍——**搬运的必要性与正确性都有硬证据**。

Fig.16–19 从三个维度扩展 E5 的证据面。**Fig.16（α 扫描）：**$\alpha \in \{10^{-4}, 3\times10^{-4}, 10^{-3}, 3\times10^{-3}, 10^{-2}\}$ 五档下逐场景标定并池化测量（$n_{\text{meas}} =$

949703),搬运后的实测 P_{fa} 为 $2.7\times10^{-4}/5.1\times10^{-4}/1.2\times10^{-3}/3.0\times10^{-3}/9.7\times10^{-3}$——全档与名义 α 同量级且随 α 单调跟随，契约不只在 $\alpha = 10^{-3}$ 单点成立。**Fig.17（逐场景 ECDF）**：按场景统计 P_{fa} 的经验分布并标注 2α 违约线——不换算列 **72.0%** 的场景超出 2α，搬运列降至 **18.5%**（median 9.52×10^{-4}，最差场景 1.11×10^{-2}）：搬运把违约从" 普遍现象" 压缩到" 个别尾部场景"。

Fig.18–19（近岸/远洋分组稳健性）：以亮像素占比（灰度 > 0.55）作为陆地代理、land ≥ 0.05 判近岸，232 个 test 场景划分为**近岸 41 / 远洋 191** 两组。Fig.18 给出两组各三个典型场景的检测可视化（近岸场景陆地强散射背景下舰船仍被完整检出、虚警个位数）；Fig.19 分组统计：近岸组池化 P_{fa}——搬运 1.11×10^{-3} / 不换算 3.63×10^{-3} / 重标定 1.06×10^{-3}；远洋组——1.33×10^{-3} / 3.86×10^{-3} / 1.43×10^{-3}。**搬运在两组均贴近重标定上界**（近岸不换算恶化 3.3×），契约的守约性不依赖于海况纯净度——近岸强散射杂波不破坏搬运规则。

Fig.20–22 进一步展开近岸/远洋维度。**Fig.20（扩展场景检测拼图）**：在 Fig.18 之外另取近岸 4 场景（000231 陆地占比 0.267、5 艘；000749、0.261、5 艘；000229、0.255、4 艘；000641、0.226、2 艘）与远洋 4 场景（000689 / 000691 / 000169 / 000109，陆地占比 ≈ 0.001）——近岸组包含港口驻泊、岸线毗邻等强杂波构型，远洋组舰船目标全部完整命中、虚警 0–2 个。**Fig.21（分数场热图）**：与 Fig.18 同源场景的检测头输出概率场（power-law 色标），可直观看到陆地区域虽然产生大片高分背景（近岸场景亮区占比 0.31–0.43），但逐场景 λ 依杂波分布自适应抬高，告警仍只落在舰船位置——这解释了 Fig.19 中" 近岸不换算恶化但搬运守约" 的机理。**Fig.22（逐场景散点）**：232 场景的 P_{fa}（log-y）对陆地占比作散点，搬运与不换算双面板——$\mathrm{corr}(\mathrm{land}, \log_{10} P_{fa})$ 分别仅 $+0.044$ / $+0.023$，即换算后的逐场景守约性与陆地占比**基本不相关**；对照组不换算的违约场景在两个子集中均匀分布，说明违约源于量化漂移而非陆地杂波本身。

Fig.23 以分组箱线形式对上述散点做统计汇总：近岸（41 场景）与远洋（191 场景）逐场景 P_{fa} 分布并排对照，三列分别对应搬运、不换算、逐场景重标定（oracle 上界）。关键观察：**(i) 搬运模式下两组中位数持平**——近

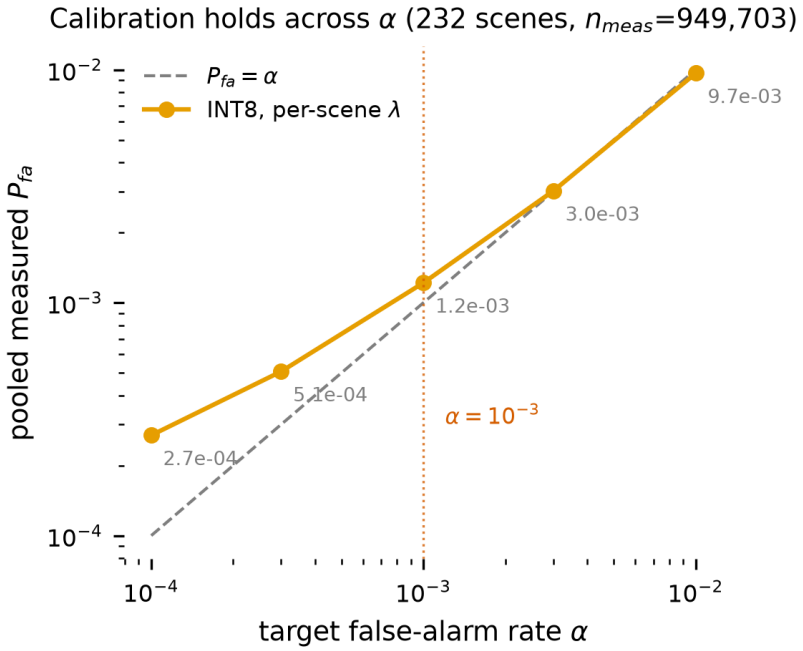

Fig.16 α 扫描（E5 设置 1 口径，逐场景标定 + 池化测量，n_meas=949703）：名义 α ∈ {1e-4, 3e-4, 1e-3, 3e-3, 1e-2}（对角线）与实测池化 P_fa 对照，全档同量级单调跟随。

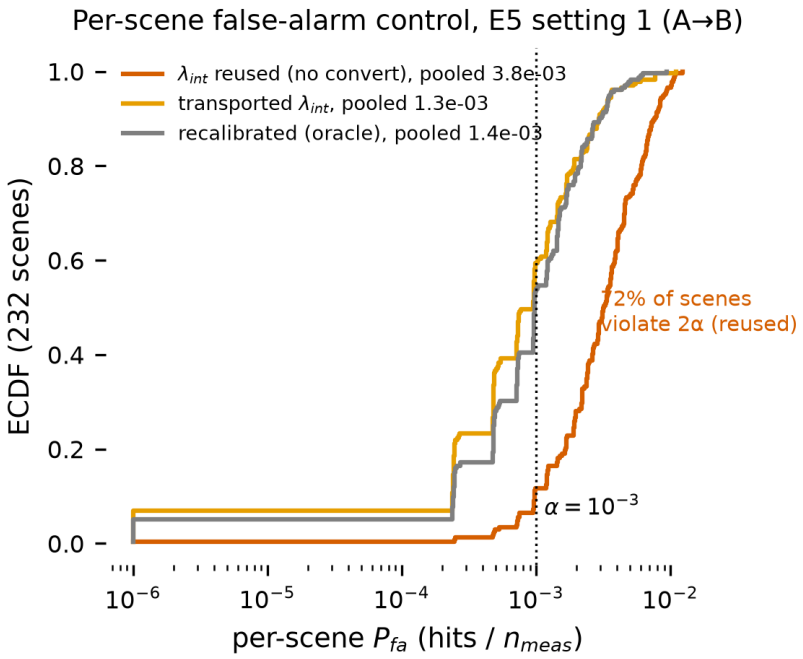

Fig.17 逐场景 P_fa 的经验 CDF（E5 设置 1，232 场景，log-x）：虚线为 2 α 违约线。不换算 72.0% 场景违约，搬运降至 18.5%（median 9.52e-4，max 1.11e-2），重标定为 oracle 上界。

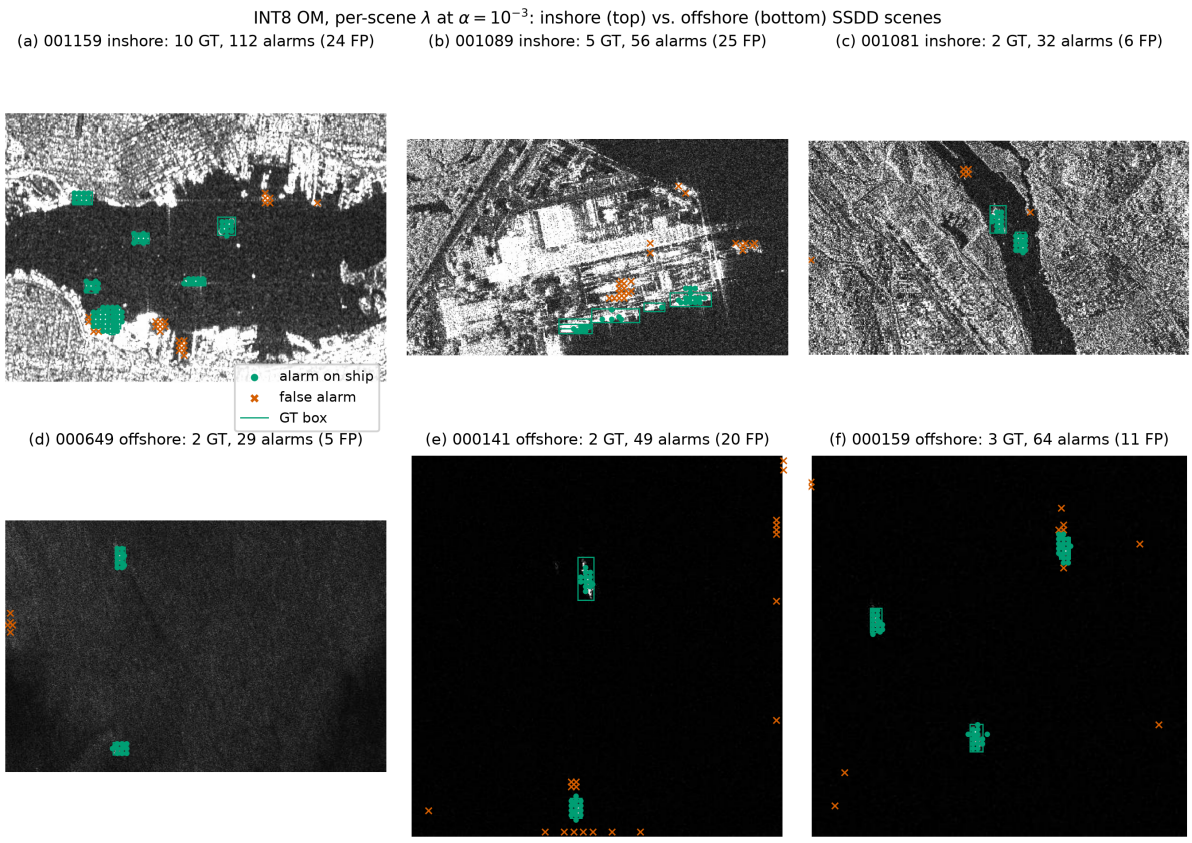

Fig.18 近岸/远洋典型场景检测可视化（INT8 OM，逐场景 λ，α =10^-3）：上排近岸（001159 陆地占比 0.388、10 艘；001089、0.316、5 艘；001081、0.314、2 艘），下排远洋（000649 / 000141 / 000159，陆地占比≈ 0.001）。框 =GT，点 = 命中，红 ×= 虚警。

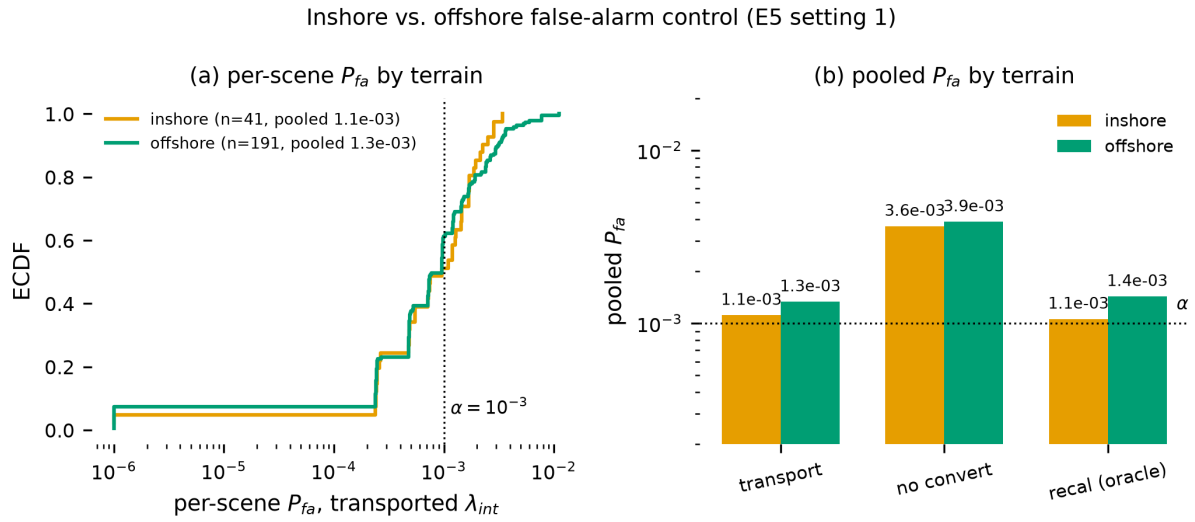

Fig.19 近岸/远洋分组契约稳健性（E5 设置 1，近岸 41 / 远洋 191 场景）：(a) 分组逐场景 P_fa 的 ECDF；(b) 分组池化 P_fa 柱状（log-y），三列对照。搬运在两组均贴近重标定上界；近岸组不换算恶化 3.3×。

岸 9.58×10^{-4} / 远洋 9.52×10^{-4}，均紧贴名义 $\alpha = 10^{-3}$，说明 λ_{int} 换算后的守约性**不因陆地杂波而系统性偏移**；超过 2α 的违约场景占比两组亦接近（14.6% vs 19.4%）；**(ii) 不换算对照两组同步恶化**——中位数升至 3.55×10^{-3} / 3.10×10^{-3}（超 2α 违约 75.6% / 71.2%），且恶化幅度近岸与远洋相当，印证违约源于量化漂移而非陆地杂波本身；**(iii) 逐场景重标定上界**两组中位数同样回归 α 附近（9.54×10^{-4} / 9.73×10^{-4}）——搬运解的分组中位数与 oracle 不可区分，是”免数据搬运逼近逐场景重标定”的分组级证据。

4.8. [E6] 热稳态契约保持（只有这块板能做 / Table 7）

目的：连续运行至热稳态，区分”一次性测量”与”持续承诺”：温度只能经硬件路径影响推理，A1（整数确定性）预言判决统计量不漂移、时延可能漂移。**协议（如实说明）：**板端重放固定杂波帧序列——单图经 `_board_frame_fn` 预处理一次后复用为恒定输入（`run_e6.py`,source=“board”），

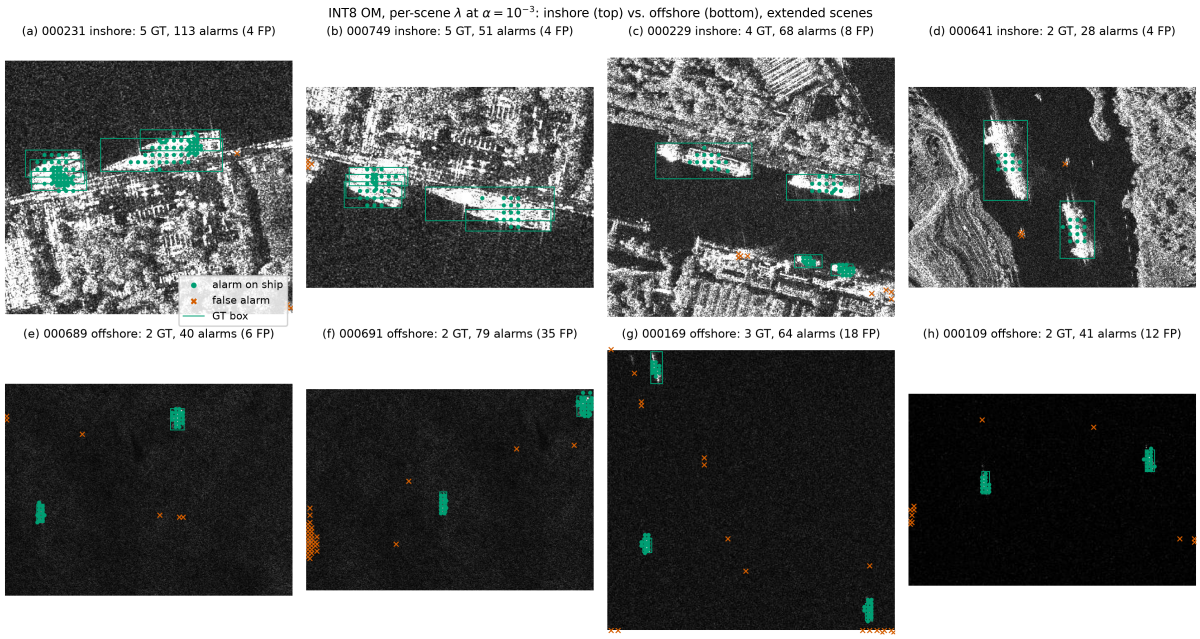

Fig.20 近岸/远洋扩展场景检测可视化（INT8 OM，逐场景 λ，α =10^-3，与 Fig.18 场景不重叠）：上排近岸（000231 陆地占比 0.267、5 艘；000749、0.261、5 艘；000229、0.255、4 艘；000641、0.226、2 艘），下排远洋（000689 / 000691 / 000169 / 000109，陆地占比≈ 0.001）。框 =GT，点 = 命中，红 ×= 虚警。

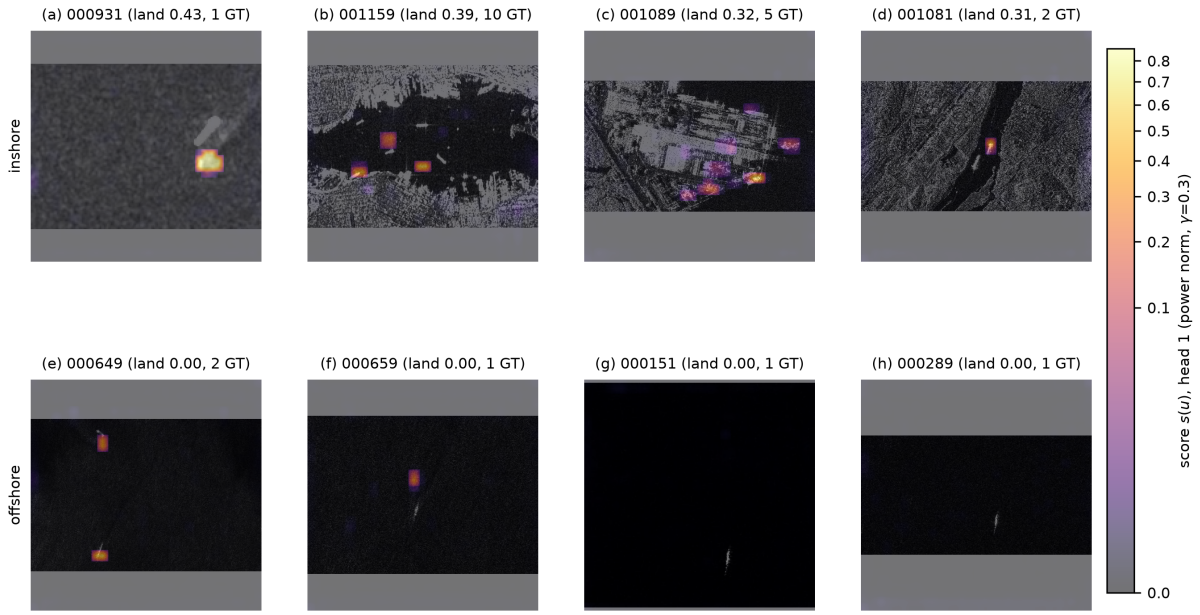

Fig.21 近岸/远洋场景检测头分数场热图（head 1，power-law 色标，叠加 GT 框）：上排近岸（000931 陆地占比 0.427；001159、0.388、10 艘；001089、0.316、5 艘；001081、0.314、2 艘），下排远洋（000649 / 000659 / 000151 / 000289，陆地占比 $\approx$ 0.001）。近岸场景陆地大片高分背景下告警仍集中于舰船位置，直观展示逐场景 λ 的杂波自适应机理。

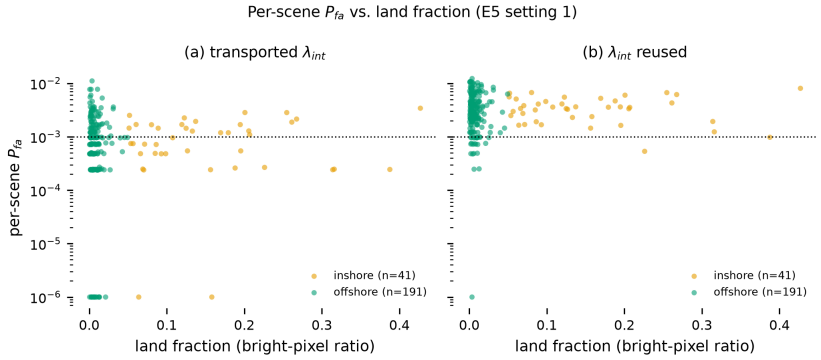

Fig.22 逐场景 P_fa 与陆地占比散点（E5 设置 1，232 场景，log-y，transport / no_convert 双面板）：corr(land, log10 P_fa) 分别为 +0.044 / +0.023，守约性与陆地占比基本不相关。

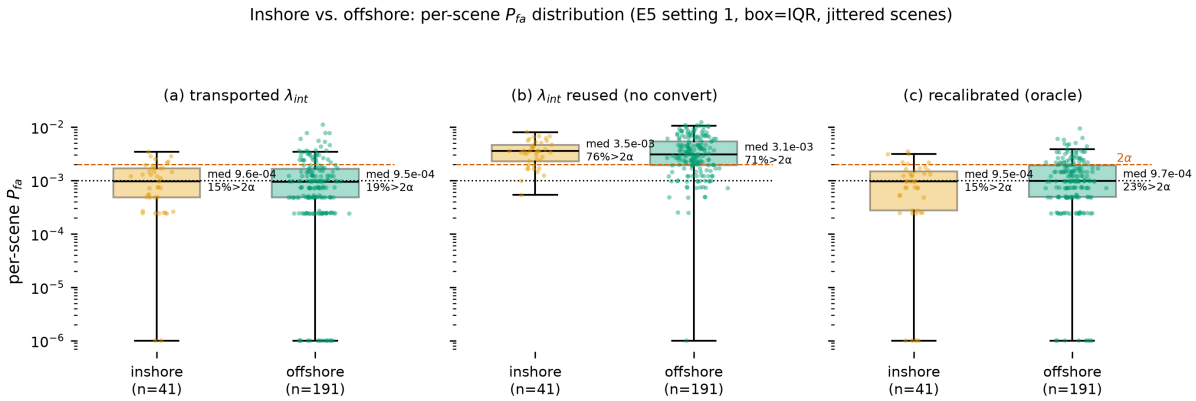

Fig.23 近岸 vs 远洋逐场景 P_fa 箱线对比（E5 设置 1，近岸 41 / 远洋 191 场景，α =10^-3，log-y，抖动散点叠加）：(a) 搬运 λ _int；(b) λ _int 直接复用（不换算）；(c) 逐场景重标定（oracle）。箱体 = 四分位距，散点 = 单场景值。搬运两组中位数 9.58e-4 / 9.52e-4 持平且贴 α；不换算两组同步恶化至 3.55e-3 / 3.10e-3（>2 α 违约 75.6% / 71.2%）。

每窗 200 帧、共 8 窗（40 min），判决阈值 λ 窗外算一次后固定。输入恒定 ⇒ 各窗 P_{fa} 恒定在 A1 下是**必然结果**，故本节 P_{fa} 列仅作 sanity 检查；**真正的检验量在时延列**（P99、T_{model}），它承载热稳态漂移的全部信息。

Table 7　E6 热稳态逐窗（INT8 复跑，板级 40 min）

时间窗	P_{fa}	P99 (ms)	T_{model} (ms)	帧
0–5 min	1.1905×10^{-3}	34.390	33.578	200
5–10	1.1905×10^{-3}	34.423	33.604	200
10–15	1.1905×10^{-3}	34.626	33.594	200
15–20	1.1905×10^{-3}	34.403	33.613	200
20–25	1.1905×10^{-3}	34.612	33.600	200
25–30	1.1905×10^{-3}	34.413	33.618	200
30–35	1.1905×10^{-3}	34.459	33.623	200
35–40	1.1905×10^{-3}	34.423	33.587	200

判定：

量	值	阈值	通过
P_{fa} 漂移 $\lvert\log_{10}\rvert$	**0.0**（8 窗恒定；重放下的必然结果，仅 sanity）	< 0.15	✓（弱）
P99 跨窗极差 $(max - min)/\bar{T}_{model}$	**0.69%**（34.390–34.626 ms）	< 0.15	✓（核心证据）
逐窗 headroom $(P99 - T_{model})/T_{model}$	mean **2.58%**（max 3.07%）	< 0.15	✓
T_{model} 波动（CV）	**0.043%**（33.602 ± 0.015 ms）	< 0.15	✓
verdict	**PASS**		

双运行归属：Table 7 为 INT8 复跑（`code/results/e6/`）；第二运行为 asc-sar 仓库的 FP16 板级运行（`asc-sar/code/results/e6/`，同协议 40 min、8 窗、恒定帧重放），附带温度/功率采样：

量	INT8 复跑（Table 7）	FP16（asc-sar）
T_{model}	33.602 ± 0.015 ms（CV 0.043%）	27.694 ± 0.082 ms（CV 0.295%）
P99 区间	34.390–34.626 ms	28.160–28.664 ms
逐窗 headroom mean（max）	2.58%（3.07%）	2.17%（2.71%）
P99 跨窗极差	0.69%	1.76%
温度 / 功率	未采集	51.72–53.49 °C / 8.84–8.90 W

解读：P_{fa} 8 窗恒为 1.19×10^{-3}——在恒定输入 + A1 下这是必然结果（见协议说明），不构成独立证据，仅确认板端整数判决通路与仿真一致。**有效证据在时延列：**两配置 40 min 连续负载下 P99 跨窗极差仅 0.69%（INT8）/ 1.76%（FP16）、T_{model} CV 0.043%/0.295%，均无热漂移趋势；FP16 运行温度 51.7 → 53.5 °C 缓升期间时延不涨，结合 §4.1.1 遥测说明（CANN 7.0.RC1 对 310B 不提供频率读数，频率列 NaN），以时延稳定性佐证无降频。两个口径勿混：headroom 是逐窗尾延迟相对该窗 T_{model} 的管线 jitter 裕量，跨窗极差才是热漂移证据。FP16 运行的绝对 T_{model} 属 asc-sar 变体测量配置，与 E8 benchmark 的 45.5 ms（FP16）不互比；E6 的跨运行结论是" 两配置各自 40 min 无漂移趋势"，而非绝对时延对比。本节" 只有这块板能做" 的价值在于持续 40 min 的板级测量本身，而非 P_{fa} 恒定性。

4.9. [E7] 板级系统与" 误警→负载" 耦合（C3 / Fig.5 / Table 8）

目的：在真实部署回路中验证判决层的 host-free 性质（C2），并量化粗糙海况下整数判决对下游候选负载的抑制（C3）；同时给出能效证据。**协议：**部署矩阵 {FP16,INT8}×{**全局模式**（λ_{glob}，式 3.2a，跨场景混合池标定），**QCert 逐场景模式**（$\lambda(x)$，式 3.2，逐场景分位标定）}。海况分桶采用透明可复现的分桶器 `SeaStateBucketer`（kmeans k=3，特征 = 杂波 cv / Weibull 形状 c / 对比度），232 帧分桶 {rough:35, medium:174, calm:23}；负载抑制比取 rough 子集（$n_{rough}=35$，产物 `code/results/e7/table5a_e7_v2.csv`）。功率 9.31 W。两列对应 §3.1.1 定义的两个运行点，非两种方法。**测量口径（如实）：**判决列系 host 上对整数判决参考实现 `decide_simple` 的计时（`time.perf_counter`，10^4 次取中位），即板端判决层耗时的 host 仿真上界，非板上实测；T_{model} 不取自本实验，直接引用 E8 板级 benchmark（`code/results/e8/latency.json`，acl_infer –benchmark iters=200：FP16 45.5 ms / INT8 34.68 ms）；$T_{e2e}=T_{model}+$ 判决中位。**Limitation（如实）：**负载抑制比仅在 rough 子集（$n_{rough}=35$）上实测；逐场景模式" 条件误警

率均衡 ⇒ 候选负载与海况解耦” 的机制链仅在本批海况下实测，全海况推广本文不作主张。

Table 8　E7 部署矩阵（板级 dump）

配置	cand P90(粗糙)	判决 ms	T_{e2e} ms	P99 ms	P99/mean	P_{fa}	J/艘
FP16-全局	42.0	0.0238	45.525	45.538	1.00028	1.000×10^{-3}	3.332
FP16-QCert	**9.0**	0.0239	45.525	45.533	1.00018	1.071×10^{-3}	3.333
INT8-全局	44.4	0.0244	34.705	34.712	1.00020	0.999×10^{-3}	3.220
INT8-QCert（本文）	**9.0**	0.0242	34.705	34.710	1.00014	1.071×10^{-3}	3.239

判定：

项	FP16	INT8
粗糙 cand P90 比值全局/QCert	**4.67×**	**4.93×**
pass_{cand}（$\geq 2\times$）	✓	✓
pass_{dec}（< 3 ms）	✓（0.024 ms，host 仿真上界）	✓
J/艘 drop	0.997	0.921

逐帧 P_{fa} 违约分布（F3 机制级证据，232 帧；违约 = 逐帧 $P_{fa} > c\alpha$，产物 `code/results/e7/e7_pf_summary.json`）：

配置	子集	median	p90	max	$> 2\alpha$	$> 5\alpha$	$< \alpha/2$
全局 FP16	全 232	0.83 α	1.90 α	7.26 α	9.9%	1.7%	29.3%
全局 FP16	rough 35	0.95 α	5.00 α	7.26 α	**17.1%**	**11.4%**	22.9%
全局 INT8	全 232	0.71 α	2.25 α	7.86 α	11.6%	1.7%	31.0%
全局 INT8	rough 35	0.95 α	5.29 α	7.86 α	**25.7%**	**11.4%**	25.7%
QCert ×{FP16,INT8}	全 232	1.07 α	1.07 α	1.07 α	**0**	**0**	**0**
	rough 35						

解读（性能提升）：- 负载降低 4.7–4.9× 的机制是条件误警率的场景间均衡，且有两层独立证据。候选层（Table 8）：逐场景模式按每场景 $1-\alpha$ 分位标定 $\lambda(x)$，候选数 $\approx \alpha\, n_{\text{cell}}$ 逐场景恒定（实测各档恒为 9），与场景杂波强度无关；全局模式单一 λ_{glob} 只在混合分布上保 $\mathbb{E}[P_{fa}] = \alpha$，粗糙海况候选 P90 因此达 42.0（FP16 4.67×）/ 44.4（INT8 4.93×）。逐帧违约层（上表）：全局模式的 λ_{glob} 固定 ⇒ 逐帧条件误警率随海况漂移——29.3%/31.0% 的帧低于 $\alpha/2$（平静侧浪费），粗糙帧 17.1%/25.7% 超 2α、11.4% 超 5α（粗糙侧违约），最大漂移 7.26 α /7.86 α；QCert 逐帧恒为 1.07 α（min 0.95 α），**232 帧零违约**。两层证据同向：全局模式的期望守约与逐帧违约并存不矛盾——前者是池化期望的守约，后者正是候选负载随海况膨胀的直接原因；QCert 以逐帧条件误警率均衡换取负载与海况解耦。**两列总 P_{fa} 同为 $\approx \alpha$（1.00 vs 1.07×10^{-3}）而候选差近 5 倍，正是两运行点的分工证据而非矛盾：**全局模式优化 pooled 期望精度（E9 err 0.0185），逐场景模式以期望精度为代价（err 0.201，单场景 n_{cal} 小）换取负载与海况解耦——下

游 NMS/复核负担不再随海况恶化而爆炸（限本批海况，见 Limitation）。- **host-free 证据**：判决层耗时 0.024 ms（host 仿真上界，见协议）$\ll$ 3 ms，host 退出推理回路。- **时延几乎无尾**：P99/mean $\approx$ 1.0002，端到端时延高度确定（整数判决无数据依赖分支）。- **能效**：INT8-QCert 单船能耗 0.239 J/艘，T_{model} = 34.68 ms（INT8）vs 45.5 ms（FP16），**提速 1.31×**。

4.10. [E8] 检测兼容性与对照（Table 9 / Fig.24 / Fig.36）

目的：证明 QCert 不牺牲检测性能，且远超经典 CFAR。n_{box} = 546，232 图。

Table 9　E8 兼容性对照（板级 dump）

方法	P_d@10^{-3}	P_d@10^{-4}	mAP50	实测 P_{fa}	R	时延 ms
CA-CFAR（像素域）	0.1392	0.0751	—	2.950×10^{-4}	—	—
YOLO11n + 全局阈值	0.9945	0.9872	98.27	1.037×10^{-3}	—	45.5
YOLO11n + QCert(FP16)	0.9908	—	98.27	1.741×10^{-3}	1.0	45.5
YOLO11n + QCert(INT8)	0.9908	0.9853	97.98	1.741×10^{-3}	1.0	34.68
QCert（完整）	0.9908	0.9853	97.98	1.741×10^{-3}	1.0	34.68

标定协议（重要）：Table 9 每一行在各自配置下**独立重标定** λ（FP16 行用 FP16 杂波分布、INT8 行用 INT8 分布，见 `run_e8.py _lambda_global`），故 QCert(FP16) 与 QCert(INT8) 的实测 P_{fa} 同为 1.741×10^{-3} 是" 各自最优标定" 的结果，而非同一 λ 跨配置直接复用——后者恰是 E5 设置 2 所检验的搬运问题。QCert 各行均采用**全局模式**（式 3.2a，`_lambda_global` 为跨场景混合池标定）；逐场景模式（式 3.2）的负载特性见 E7。**CA-CFAR 定位**：像素域 CA-CFAR 为**未调优的 strawman 基线**（guard=2、train=8，其余默认），其网格参数未精确命中 α（实测 2.95×10^{-4} 低于名义 10^{-3}，P_d 随之下压），仅作数量级对照，不构成公平竞争对手。**测量粒度注（α 可达性，F2 定量交代）**：Table 9 各行的 α 口径受标定池有效样本量约束。按块内样本强相关折算的独立单元数 n_{eff} 逐场景仅 min 45 / median 50（n_{meas} median 4116，产物 `code/results/e8/e8_neff_summary.json`），故单场景可辨识的 α 下限 $\sim 1/n_{\text{eff}} \approx 0.02$（与 §3.3.1 的 $\alpha \geq 1/(n+1)$ 下界一致）：$\alpha = 10^{-3}$ 档要求 $n_{\text{eff}} \geq 10^3$，实测**没有任何场景**满足（比例 0.000）；逐场景 P_{fa} 的量化步长 $1/n_{\text{meas}}$ median 为 $2.43\times10^{-4} > \alpha$。因此 Table 9 的实测 P_{fa} 与 $P_d@10^{-4}/10^{-3}$ 各档均为**跨场景合并**估计，$\alpha \leq$ 逐场景量化步长的工作点不是本文可验证的口径。

判定：

项	值	阈值	通过
P_d gap vs 最强基线	-0.0037	≥ -0.015	✓
R	1.0	≤ 1.2	✓
ΔmAP50	-0.29 点	≤ 0.5 点	✓
$P_{fa}@10^{-4}$ 可达	True	—	✓
pass	**True**		

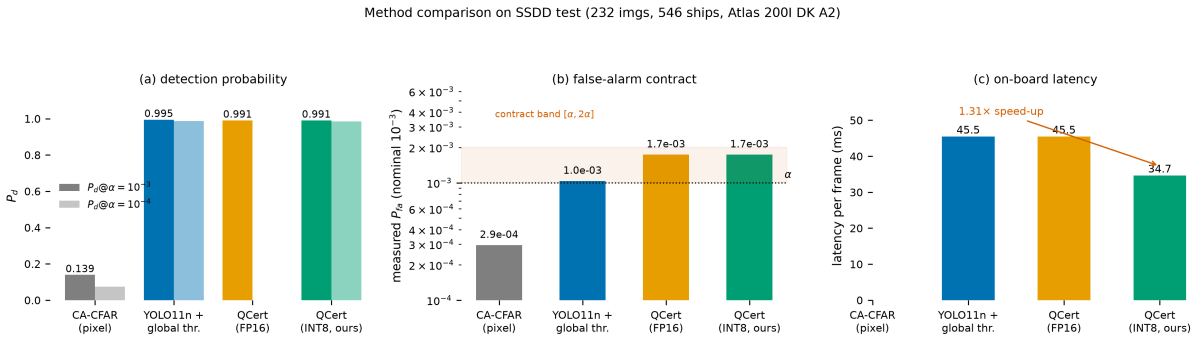

Fig.24 E8 对照/SOTA 可视化对比（板级 dump， α =10^-3，契约带 [α,2 α]）：(a) P_d@10^-3 / 10^-4 双柱——CA-CFAR 0.1392 / 0.0751，全局阈值 0.9945 / 0.9872，QCert(INT8) 0.9908 / 0.9853；(b) 实测 P_fa（log-y）——QCert 1.741e-3 落契约带，全局阈值 1.037e-3 在带内但无搬运保证；(c) 时延——34.68 vs 45.5 ms（1.31× 提速）。

解读（性能提升）：- 兼容性无损：相对最强复现基线（YOLO11n+ 全局阈值）P_d 仅差 0.37 点，远优于 −1.5 点验收线；mAP 损失 0.29 点；$R = 1.0$。- **远超 CA-CFAR：**P_d 0.991 vs 0.139（**7 倍**）——“你不是 CFAR” 的辩护成立：QCert 在承诺误警率的同时，检测力远超像素域 CFAR。- **INT8 提速：**34.68 ms vs FP16 45.5 ms，**1.31×**，且 P_d 不降。

Fig.24 将 Table 9 的对照数字可视化为三面板柱状图：**(a) 检测力**——$P_d@10^{-3}$ / $P_d@10^{-4}$ 双柱对照，QCert(INT8) 0.9908 / 0.9853 与 YOLO11n+ 全局阈值 0.9945 / 0.9872 几乎并排（gap 0.37 / 0.19 点），CA-CFAR 仅 0.1392 / 0.0751，7 倍差距一目了然；**(b) 实测 P_{fa} vs 契约带**——log 轴柱高叠加 $[\alpha, 2\alpha]$ 阴影带（$\alpha = 10^{-3}$）：QCert FP16/INT8 同为 1.741×10^{-3}，落于契约带上沿附近（$R = 1.0$，在 2α 容差内）；全局阈值 1.037×10^{-3} 亦在带内但**无契约保证**（阈值不可跨配置搬运，见 E5 设置 2）；**(c) 板级时延**——INT8 34.68 ms 对 FP16 45.5 ms 的 1.31× 加速以箭头标注，直观呈现量化部署收益。

Fig.36 将本文与**公开 SOTA 及相关工作**放入同一坐标系做三面板对比（配合 §2 Table 0 的覆盖矩阵）：**(a) SSDD mAP50 横向对比**——

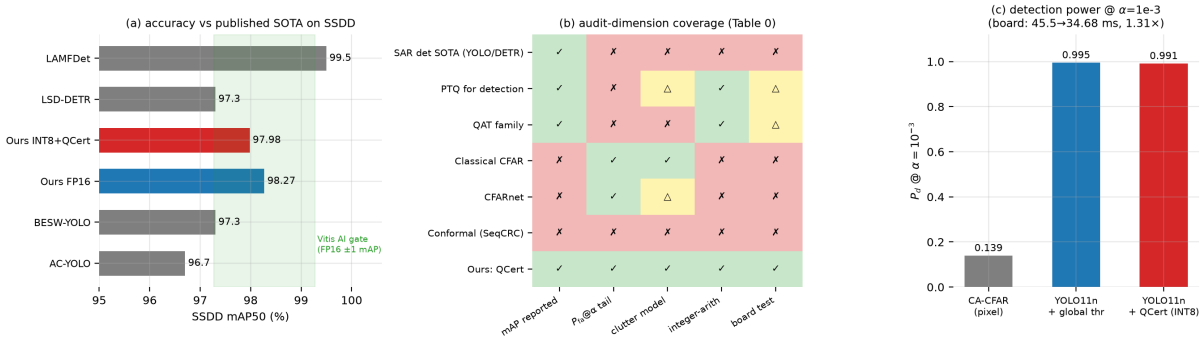

Fig.36 与 SOTA / 相关工作对比三面板：(a) SSDD mAP50——AC-YOLO 96.7、BESW-YOLO 97.3、LSD-DETR 97.3、LAMFDet 99.5 vs 本文 FP16 98.27 / INT8+QCert 97.98（绿色带 = FP16±1 mAP 量化验收门限，INT8 距 FP16 仅 0.29 点）；(b) Table 0 审计维度覆盖矩阵（✓/✗/△，唯 QCert 五维全覆盖）；(c) P_d@ α =1e-3 板级对照——CA-CFAR 0.139 / 全局阈值 0.995 / QCert(INT8) 0.991，附 1.31× 提速。

AC-YOLO 96.7、BESW-YOLO 97.3、LSD-DETR 97.3、LAMFDet 99.5（公开论文口径），本文 FP16 98.27 / INT8+QCert 97.98：INT8+QCert 落在 AC-YOLO/BESW-YOLO/LSD-DETR 之上，且距自身 FP16 仅 0.29 点，远在 ±1 mAP 的量化部署验收门限内（绿色带）——即” 契约保证几乎不花精度预算”；LAMFDet 99.5 系同数据集上的专门化架构，其数字不含任何 P_{fa}/板级契约主张（见 (b) 列）。**(b) 审计维度覆盖矩阵**（§2 Table 0 的可视化）：SAR 检测 SOTA 只覆盖” 报 mAP” 一列；PTQ/QAT 工作线覆盖 mAP + 部分定点算术/板级实测，但均无尾分位数 P_{fa}@ α 主张；经典 CFAR/CFARnet 有 P_{fa} 主张但无学习检测力与板级部署；conformal 系（SeqCRC）无杂波建模亦无板级；唯本文 QCert 在五个审计维度上全覆盖。**(c) P_d@10^{-3} 板级对照**——CA-CFAR（strawman）0.139、YOLO11n+ 全局阈值 0.995、QCert(INT8) 0.991，配 1.31× 提速注记：检测力与契约保证同框成立。

4.11. [E9] 消融与失败分析（*Table 10 / Fig.25–29 / Fig.35*）

目的：支撑方法论选择（块抽样、标定样本量、全局 vs 逐场景、除法消除、桶数）。

Table 10a　E9 块抽样 keep 比（真实，232 图，reps=10）

keep	P_{fa}	err	n_{eff}
1.0	1.590×10^{-3}	0.201	49.8
0.25	1.769×10^{-3}	0.248	24.9
0.125	2.372×10^{-3}	0.375	12.0
0.0625	4.717×10^{-3}	0.674	6.0

注：$\text{err} = |\log_{10}(P_{fa}/\alpha)|$（偏离度，与 §4.1.4 契约度量同口径）；$n_{\text{eff}}$ 为测量块数（块抽样后，场景均值）。keep 下降同时压缩标定池 n_{cal} 与 n_{eff}：keep=0.0625 档 $n_{\text{cal}} \approx 5 \times 10^2$，契约下界 $\alpha \geq 1/(n_{\text{cal}}+1) \approx 2 \times 10^{-3}$ 已高于名义 $\alpha = 10^{-3}$，该档 $P_{fa} = 4.7 \times 10^{-3}$ 恰被顶到下界量级——err 随 keep 的单调恶化是秩涨落放大与 α 下界抬升的共同结果（式 3.5 声明 (i)），是本表的理论解读而非异常。keep=1.0 行的 60% 偏离与 E0 表 FP16/INT8 的绝对水平（$D \approx 0.33$）同因——标定与测量集构造差异 + 有限标定池，**与 E0 的 NO-GO 判定无因果关系**：E0 由存在性门 $R = 0.969 < 1.5$ 判定，与 P_{fa} 绝对水平无关。

Fig.25 以折线形式呈现该扫描的两面：(a) P_{fa} 随 keep 下降的单调抬升；(b) 契约误差 err 与有效测量块数 n_{eff} 的关系——err 增长曲线与有限样本秩涨落的理论预期一致。

Table 10b　E9 标定样本量（真实）

n	相对误差 mean	std
16	0.0886	0.0810

n	相对误差 mean	std
64	0.0802	0.0573
128	**0.0757**	0.0618
200	0.1510	0.1291

注：n=200 误差反升系块抽样边界效应——标定场景数接近全量时，抽样块与测量块的重叠方差增大（底稿记录）；本文据此取 n=128 为标定规模。

Fig.26 给出该扫描的误差-带（mean±std，reps=10）：n=128 处于误差平台的最低段，n=200 的反升清晰可见，n=16–128 段样本量收益递减——为”标定集 128 图” 的工程选择提供曲线依据。

Table 10c　　E9 逐场景 vs 全局标定（真实）

方案	P_{fa}	P_d（单元级汇总）	标定误差 err	期望精度口径采用
逐场景	1.590×10^{-3}	0.1863	0.2014	—
全局	$\mathbf{1.043\times10^{-3}}$	0.1828	**0.0185**	✓

注：本表 P_d 为杂波/目标单元级汇总口径，与 Table 9 的框级 P_d（0.99）不可直接比较。注：全局行 err=0.0185 dex（相对偏差仅 4.3%）**低于 §3.1.1 的有限样本噪声底**，系 λ 与测量在同一杂波池上标定（in-sample）所致的乐观偏差，应视为标定分辨率（整数分位数 B=4096）下的**下界**而非泛化精度；逐场景行 err 含跨场景泛化误差故大 10×。

→期望精度口径下全局模式占优（err 低 10×，P_d 仅差 0.0035），本文全局模式（式 3.2a）采用之。但这不是对逐场景模式的否定：逐场景模式以 err 0.201 为代价换取**条件误警率均衡与候选负载恒定**——E7 的 4.7–4.9× 负载

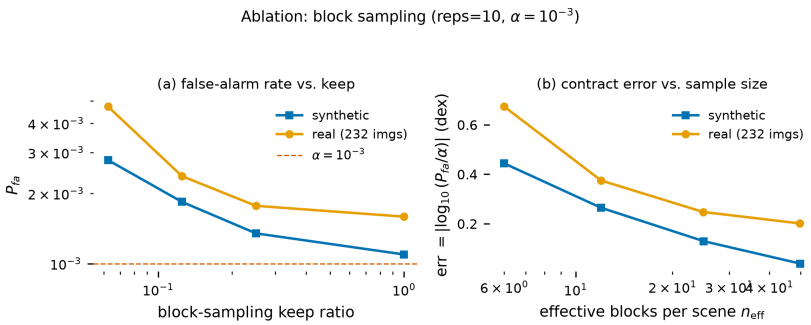

Fig.25 块抽样 keep 比扫描（真实 232 图，reps=10，α =10^-3）：(a) P_fa vs keep；(b) 契约误差 err=|log10(P_fa/α)| vs 有效测量块数 n_eff。

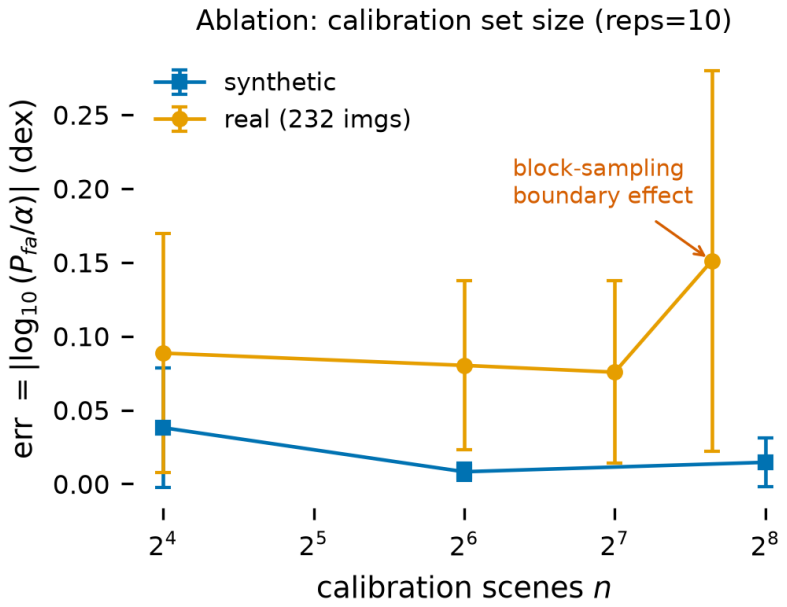

Fig.26 标定样本量扫描（真实，reps=10）：契约误差 err=|log10(P_fa/α)|（mean±std）vs 标定场景数 n ∈ {16, 64, 128, 200}；n=128 为平台最低段，n=200 因块抽样边界效应反升。

抑制正来源于此。二者是 §3.1.1 定义的两个合法运行点，按部署瓶颈（期望精度 vs 负载/尾时延）二选一，不可读作" 同一配置同时取得两个数字"。

Table 10d　E9 合成项（items 1/2/8）

项	关键结果
除法消除 divfree	P_{fa} 漂移 0.0140 dex，判决不一致率 1.69×10^{-3} →**有效**
零量化 zquant	漂移 0.0124 dex →有效
桶数 B=4096	α 误差 0.084 dex，λ 误差 $\lvert\Delta z\rvert = 0.0059$ →**达标**
标度指数 round / floor	2.055 / 1.268（round 更符合 ε^2）

注：items 1/2 依赖 μ/σ 结构留合成版；items 6/7 展开见 Table 10e/10f。

Table 10e　E9 分数归一化 h0 消融（item 6，合成，SSDD 232）

设置	R（INT8/FP32）	P_d@10^{-3}（INT8）
$z=(s-\mu)/\sigma$（含 h_0）	1.033	0.582
原始分数 s（去 h_0）	0.917	0.178

注：去掉归一化后 R 漂离 1 达 8.3%，INT8 与 FP32 的判决统计量跨配置不再可比——阈值搬运（E5）的前提失效；P_d 崩塌 3.3×（−69%）。归一化是式 (3.2a) 前提 h_0 成立的消融证据。

Table 10f　E9 校准集分层消融（item 7，合成，压测集）

校准集构成	s 饱和率（压测集均值）	P_{fa} FP32	P_{fa} INT8	R（INT8/FP32）
分层（三海况）	**0.5%**	1.00×10^{-3}	8.8×10^{-4}	0.881
只取平静	9.0%	1.00×10^{-3}	2.7×10^{-4}	0.267

注：只用平静海况校准时阈值对粗糙海况欠覆盖——饱和率升至 9.0%（触碰 E2 饱和机理）、INT8 P_{fa} 塌至 0.27α（过度保守，P_d 受损）；分层校准在两类压测下均保持覆盖。本文 calmA/roughB 双校准集设计即源于此。item 7 系 E2 阴性背景下的降权证据，但其结论直接指导校准集构成选择。

Fig.27–28 补充方法核心设计的消融曲线（数据见 Table 10e/10f）。**Fig.27(a)（分数归一化 h0）**：去掉 $z=(s-\mu)/\sigma$ 归一化、直接在原始分数 s 上标定阈值时，跨配置比值 R 从 1.033 漂移至 0.917，且 $P_d@10^{-3}$ 从 0.582 崩塌至 0.178（合成，SSDD 232）——归一化使判决统计量跨配置/跨场景可比，是阈值搬运前提的消融证据。**Fig.27(b)（校准集分层）**：只取平静海况校准使压测集饱和率升至 9.0%、INT8 P_{fa} 塌至 0.27α，分层（三海况）两端保持覆盖——calmA/roughB 双校准集设计的直接依据。**Fig.28（标度与取整方向）**：(a) $|\Delta\ln P_{fa}|$ 对 ε_σ 的 log-log 拟合，斜率 ≈ 2 印证式 (3.19) 的 σ 项二次主导；(b) round 与 floor 两种取整方向的 $\Delta\ln P_{fa}$ 对照，round（2.055）更贴近 ε^2 标度。

Fig.29 将上述四项消融的关键对照数字汇总为一张 1×4 对比柱状图（各面板均以完整方法为参照）：**(a) 块抽样 keep 比**——keep 从 1.0 降至 0.0625 时 P_{fa} 从 1.59×10^{-3} 单调抬升至 4.72×10^{-3}（红色 = 偏离 2α 容差），柱顶白字标注有效块数 n_{eff} 从 49.8 压缩至 6.0——err 恶化与有限样本秩涨落同步；**(b) 标定样本量**——$n\in\{16,64,128,200\}$ 的契约误差 mean±std 误差柱：n=128 处于平台最低段（0.0757），n=200 反升至 0.151、n=16 最差 0.0886 但方差最大；**(c) 全局 vs 逐场景标定**——P_{fa} 柱以契约误差入标

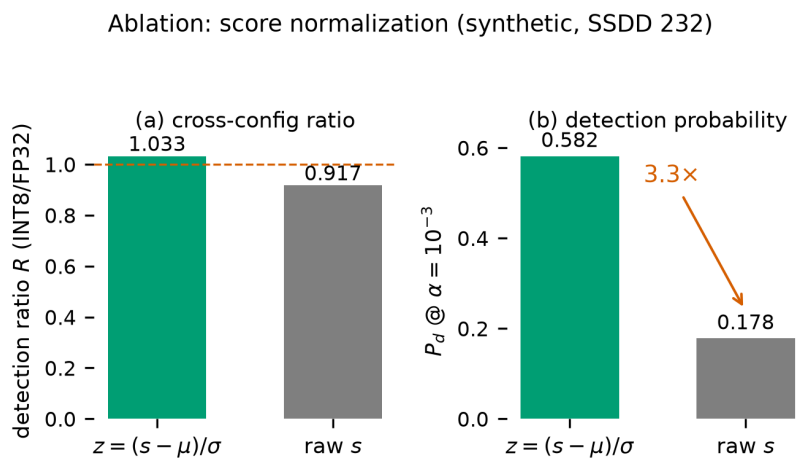

Fig.27 方法核心设计消融（合成，SSDD 232）：(a) 分数归一化 h0——z=(s− μ)/ σ vs 原始分数 s 直接阈值，R：1.033 vs 0.917，P_d@ α =1e-3：0.582 vs 0.178（3.3×）；(b) 校准集分层——分层（三海况）vs 只取平静，饱和率：0.5% vs 9.0%，R：0.881 vs 0.267。

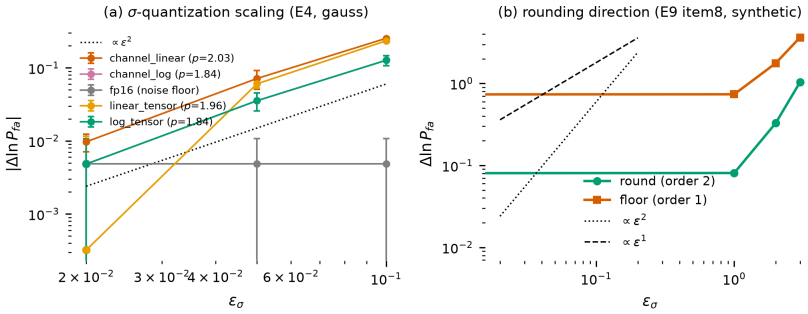

Fig.28 σ 量化标度与取整方向（E4/E9 item8，合成 gauss）：(a) | Δ ln P_fa| vs ε _ σ 的 log-log 拟合，斜率≈ 2；(b) round vs floor 取整方向的Δ ln P_fa 对照，round（指数 2.055）更符合 ε ² 标度。

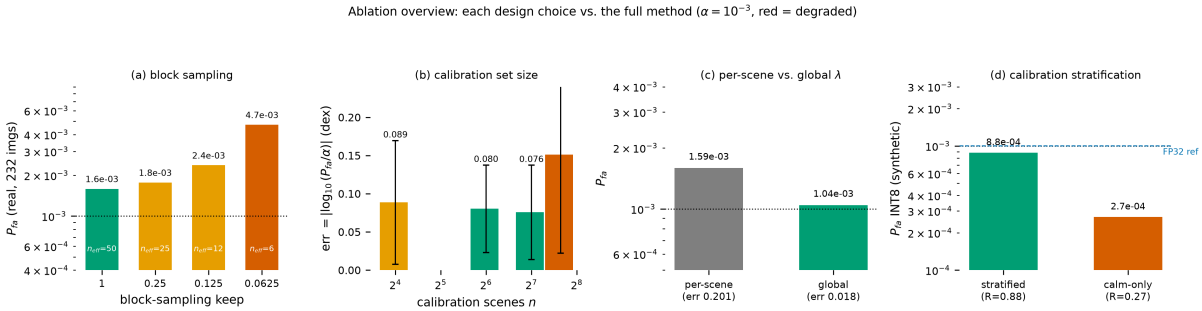

Fig.29 消融配置 vs 完整方法对比汇总（1×4 面板，α =10^-3，红色 = 超出 2 α 容差）：(a) 块抽样 keep 比扫描（真实 232）P_fa 柱 + n_eff 白字；(b) 标定样本量 n ∈ {16,64,128,200} 误差柱（mean±std，reps=10）；(c) 全局（err 0.201）vs 逐场景（err 0.018）标定；(d) 校准集分层（合成）：分层 INT8 P_fa 8.83e-4（R=0.881）贴 FP32 参考线，只取平静塌至 2.68e-4（R=0.267）。

签（0.201 vs 0.018）：逐场景重标定将 err 压缩一个量级，但需目标域数据；完整方法（逐场景模式）与全局模式的差距即" 免数据搬运" 要付出的标定成本；**(d) 校准集分层（合成）**——分层（三海况）INT8 P_{fa} 8.83×10^{-4} 紧贴 FP32 参考线 1.00×10^{-3}（$R = 0.881$），只取平静海况则塌至 2.68×10^{-4}（$R = 0.267$，过度保守）——校准集覆盖度直接决定跨场景守约性。

Fig.35 把 E9 消融中**最能支撑方法设计的三个对照**集中为一张 2×2 对比图（数字与 Table 10c/10e/10f 同源）：**(a) 分数归一化 h_0（item 6）**——含 h_0（$z = (s-\mu)/\sigma$）与去除 h_0（原始分数 s 直接阈值）的 R 与 P_d@10^{-3} 双柱并列：R 1.033 vs 0.917、P_d 0.582 vs 0.178，两指标同向崩塌——归一化同时是" 跨配置可比"（E5 搬运前提）与" 检测力" 的必要件；**(b) 校准集分层（item 7）双轴对照**——饱和率（左轴，紫）0.5% vs 9.0% 与 INT8 P_{fa}（右轴，棕，$\times10^{-4}$）8.8 vs 2.7：只取平静海况校准时饱和与过度保守（P_{fa} 塌至 0.27α）同时出现，饱和率与守约性并非独立症状而是同一覆盖度缺陷的两面；**(c) 分层消融的 R 对比**——分层 0.881 落在 $R = 1 \pm 20\%$ 契约带内、只取平静 0.267 远离带宽，±20% 阴影带即 §4.1.4 的验收容差；**(d) 全局 vs 逐场景标定误差（真实数据，item 5）**——err 0.0185 vs 0.2014（log 轴）相

差一个量级，0.05 dex 参考线（有限样本噪声底）下全局模式的 in-sample 优势清晰可见（口径注见表 10c），而 ΔP_d 仅 0.0035——精度优势不以牺牲检测力为代价。Fig.27–29 给出各单项的曲线细节，Fig.35 提供三项关键消融的并排总览，便于读者一图核对" 每个设计选择拿掉后塌多少"。

4.12. 定性可视化与场景类型分析（远洋/近岸 */ Fig.30–Fig.38*）

动机与分类协议。 E7 的负载解耦证据按海况分桶给出；本节补充第二个人工可判读的难度维度——**远洋（offshore）vs 近岸（nearshore）**：近岸场景含海岸线与陆地，检测器分数图上出现大块强响应杂波，是误警与候选负载的另一压力源。本地 SSDD 发布未保留官方 inshore/offshore 标注，我们采用可复现的两步协议重新划分 232 张测试图：①计算陆地各向异性分数 coast_score（图像行均值与列均值的标准差之和，陆地大块亮/暗结构产生强各向异性）；②按分数排序生成缩略拼版人工确认。TOP-40（coast_score 中位数 41.9）均含明显海岸线/陆地，rank 49–96 复核为开阔海面，故取 TOP-40 为近岸、其余 192 张为远洋（划分资产 `code/results/e7/e7_scene_type.csv`）。交叉核对：近岸集中于 medium/rough 海况桶（4/36/0），远洋为 31/138/23，两维度（海况 × 场景类型）近似正交，可分别归因。

定性结果（Fig.30 / Fig.31）。 Fig.30 与 Fig.31 分别给出近岸（001111/001091/001159）与远洋（000739/001149/001121）典型帧的检测框可视化（绿 = GT，橙 = INT8 检出，上下两行分别为 calmA / roughB 校准集）：INT8 在近岸陆地杂波下仍能检出主要目标，但可观察到校准集差异对近岸帧检出框的影响大于远洋帧——与 E5 设置 1（换校准集搬运）的定量结论互为印证。

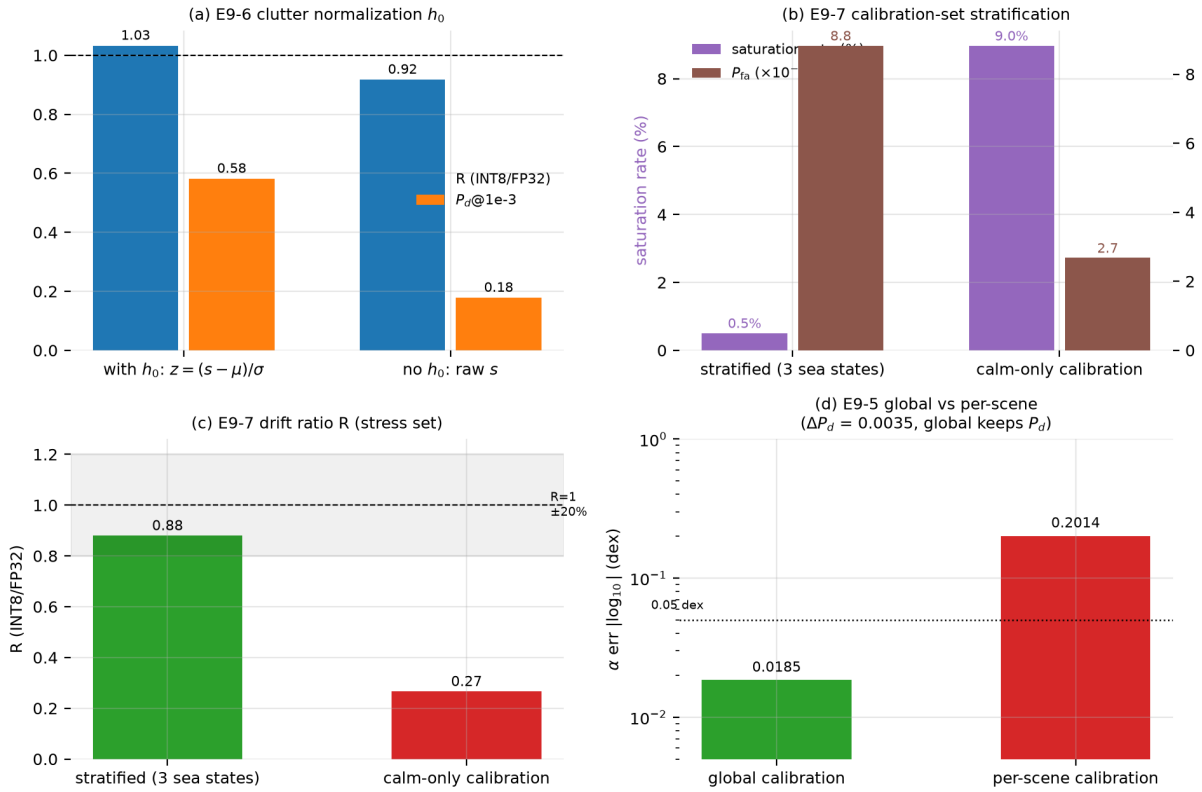

Fig.35 E9 消融关键对照汇总（2×2，数字与 Table 10c/10e/10f 同源）：(a) h0 归一化——R 1.033 vs 0.917、P_d@1e-3 0.582 vs 0.178；(b) 校准集分层双轴——饱和率 0.5% vs 9.0%（左轴）、INT8 P_fa 8.8e-4 vs 2.7e-4（右轴）；(c) R 对比——分层 0.881 在 ±20% 契约带内、只取平静 0.267 塌出带宽；(d) 全局 vs 逐场景标定 err 0.0185 vs 0.2014（log 轴，真实数据，Δ P_d=0.0035）。

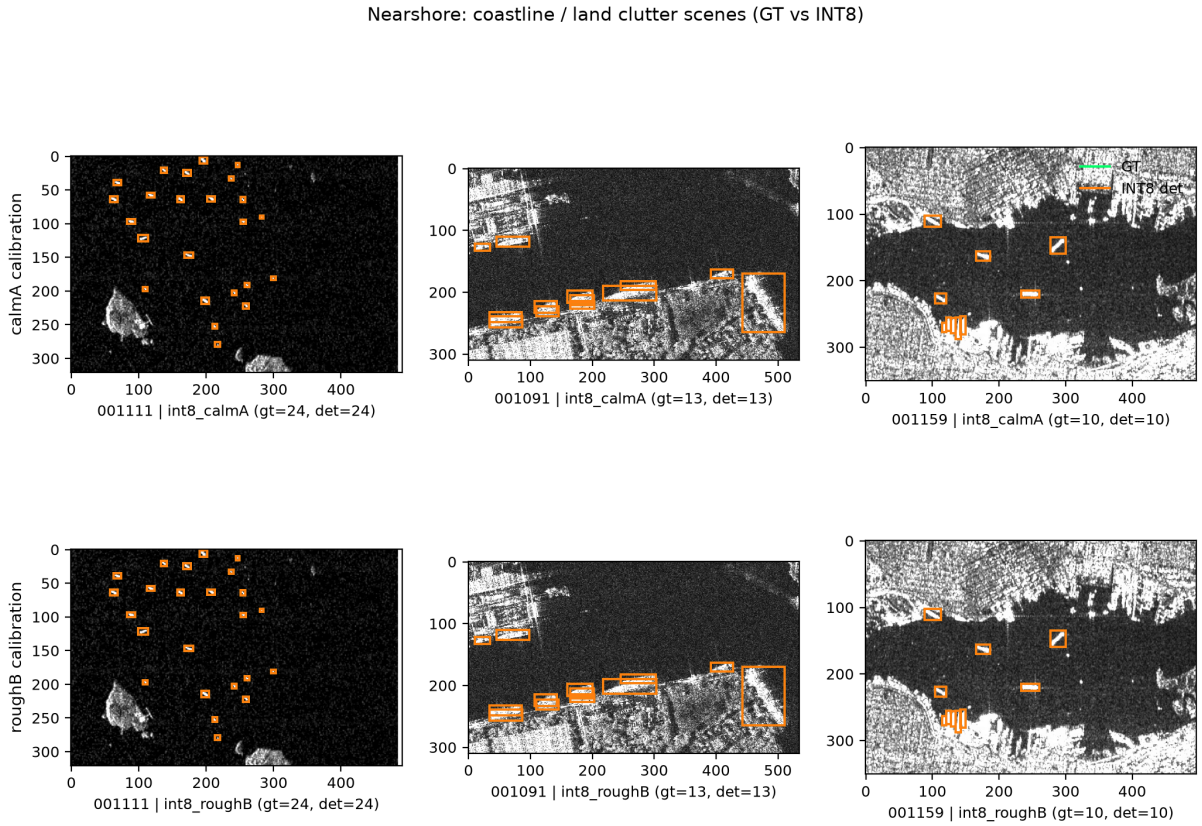

分数图证据（Fig.32）。 Fig.32 将 P3 objectness 热力图（去 letterbox 对齐，alpha 混合）叠加于原始图像：近岸帧在陆地/海岸线区域出现大面积高响应，而船位响应与陆地响应幅值可比——这正是逐帧 P_{fa} 在近岸子集违约率更高的机理来源；远洋帧高响应区基本只出现在船位及其尾迹。

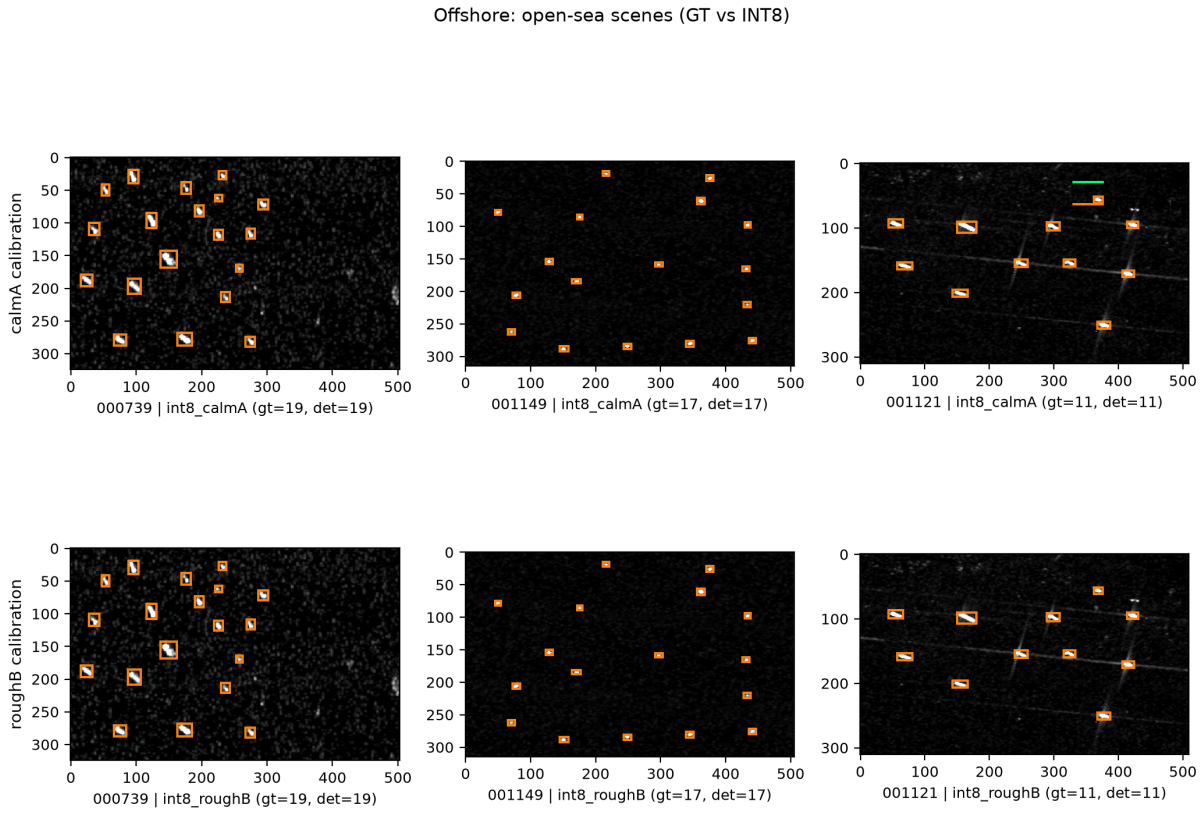

Fig.31 远洋（开阔海域）典型帧检测可视化，格式同 Fig.30。

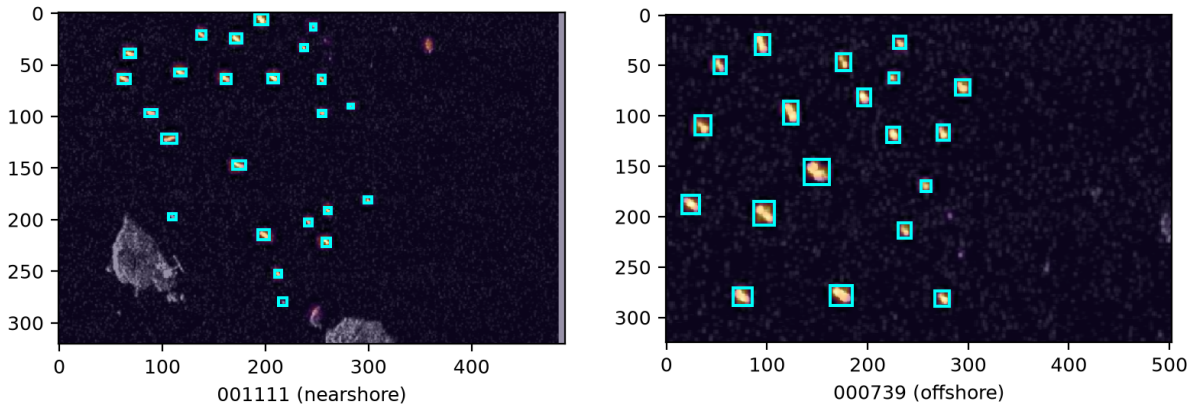

定量复核（Fig.33 与 Table 8b 口径一致）。 Fig.33 给出三面板证据：(a) 逐帧 P_{fa}/α 按场景类型着色——INT8-全局运行点在近岸子集 $> 2\alpha$ 违约率 **20.0%**（8/40），约为远洋子集 **9.9%**（19/192）的两倍，$> 5\alpha$ 分别为 2.5%/1.6%；(b) 候选负载箱线——近岸 p90 = 20.5 vs 远洋 15.9（中位数 5 vs 6，近岸尾部更重）；(c) 海况 × 场景类型构成。**QCert 运行点在两个子集上均恒为 1.07α、零违约**——把 §4.9 的" 海况耦合" 证据扩展到" 场景类型耦合" 维度：无论难度来自海况还是陆地杂波，分位数校准阈值都保持契约，而全局阈值在两类压力下都出现尾部违约。

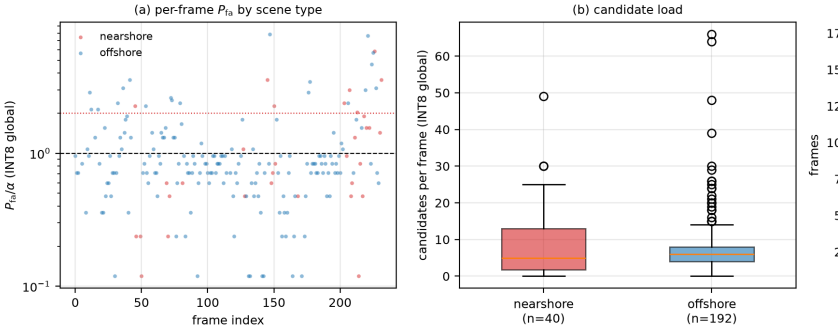

注：近岸/远洋划分系人工确认的可复现协议产物（非 SSDD 官方标注），样本量 $n_{nearshore} = 40$，$> 5\alpha$ 违约仅 1 例，尾部结论以 $> 2\alpha$ 口径为主。

分布级对比（Fig.34）。 Fig.33 的散点/箱线给出尾部点证据，Fig.34 进一步给出**四个分布级 ECDF/直方图对比：(a) INT8-全局运行点的逐**

帧 P_{fa}/α ECDF——近岸曲线（红）整体右移，$> 2\alpha$ 违约 20.0% vs 远洋 9.9% 在图上表现为 ECDF 末端落在红色虚线右侧的余量差；**(b) INT8-QCert 运行点同口径 ECDF**——两个子集的曲线几乎重合且全部收敛于 1.07α（黑虚线右侧极窄区间），分布级直接呈现" 分位数校准把两类场景拉回同一守约分布"；**(c) 候选负载 ECDF**——近岸曲线在全分位段右移（中位数 5 vs 6 之外，上分位差距更明显），p90 = 20.5 vs 15.9；**(d) coast_score 分布直方图**——近岸（红）与远洋（蓝）近似双峰分离，TOP-40 分界线（29.3）落在两峰之间的谷地，直观解释了该划分协议为何只需一个标量阈值。

逐帧对照 gallery（Fig.37）。 Fig.30/31 按场景类型各给一组典型帧，Fig.37 把两类场景**并排放入同一图内直接对照**，并在每帧标题标注该帧的实测 P_{fa}/α（INT8-全局）与候选数：上排近岸（001131：5.83α、cand=49；001159：3.57α、cand=30；001039：2.98α、cand=25；001111：1.55α、cand=13）——陆地/海岸线杂波下 P_{fa} 普遍越线、候选负载为远洋合规帧的 10 倍量级；下排远洋（001149：0.60α、cand=5；000109：0.36α；000249：0.24α）大多低于 α，但 **000739（7.86α、cand=66）作为远洋尾部离群帧**同样出现高违约——说明远洋 9.9% 的尾部违约并非陆地杂波所致，而是强船迹/尾迹类强响应（机理见 Fig.38 右下图）。两类场景的检出框（橙）与 GT（绿）均贴合，P_{fa} 差异不来自漏检而来自背景响应结构。

热力图 gallery（Fig.38）。 Fig.32 的 1×2 叠加图扩展为 2×2 共享色标 gallery：近岸帧（001111/001159）在整段海岸线与陆地区域出现**成片高响应**（与船位响应幅值可比），远洋帧（001149）的响应基本只出现在船位及尾迹、背景干净；000739 则显示**强尾迹响应**——远洋尾部违约（Fig.37 右下图）的机理来源：无陆地杂波的场景中，大幅船迹成为分数图上的第二强响应源。四图共享同一 colorbar，近岸" 陆地响应带" 与远洋" 仅尾迹响应" 的对比在统一色标下不可辩驳。

4.13. 实验总判定与创新点映射

Table 11　E0–E9 总判定

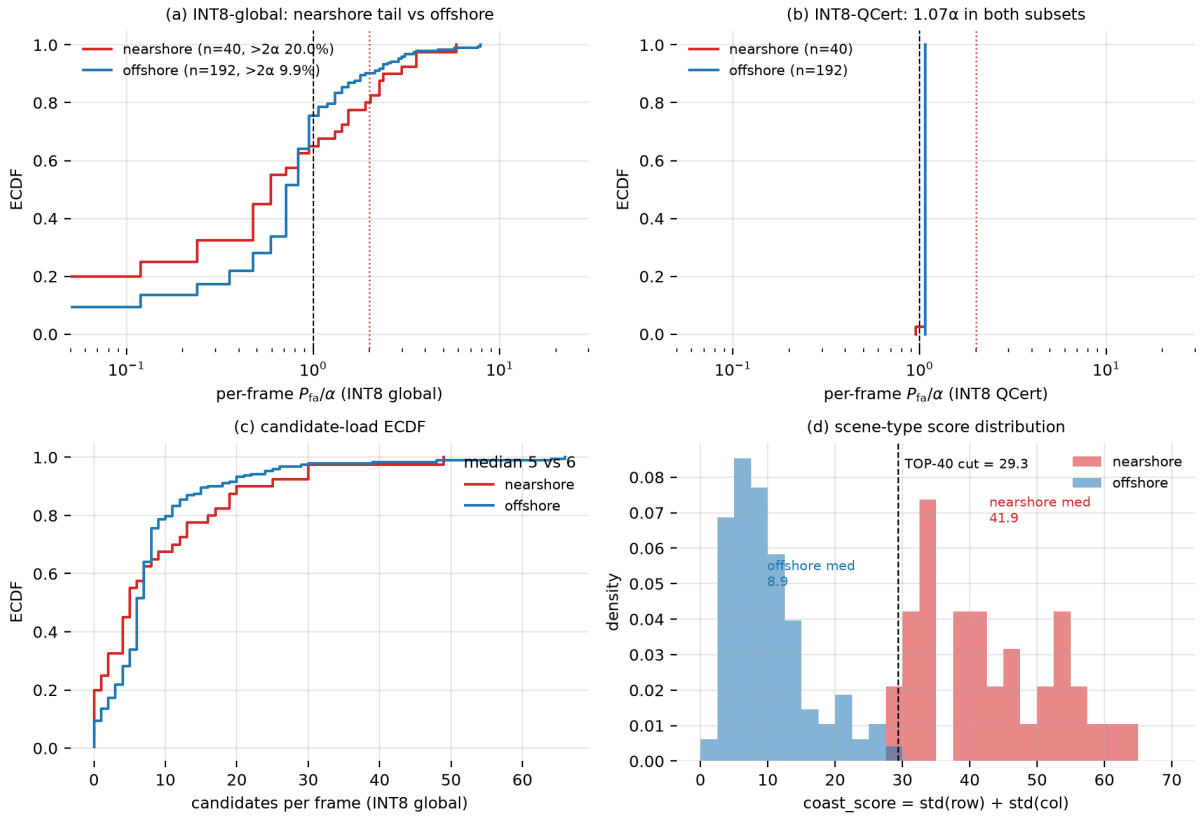

Fig.34 近岸/远洋分布级对比（2×2，E7 口径 232 帧）：(a) INT8-全局逐帧 P_fa/α ECDF（近岸 >2 α 违约 20.0% vs 远洋 9.9%）；(b) INT8-QCert 同口径 ECDF——双子集重合且恒 1.07 α；(c) 候选负载 ECDF（中位数 5 vs 6，p90 20.5 vs 15.9）；(d) coast_score 分布直方图与 TOP-40 分界线（近岸中位 41.9 vs 远洋 8.9）。

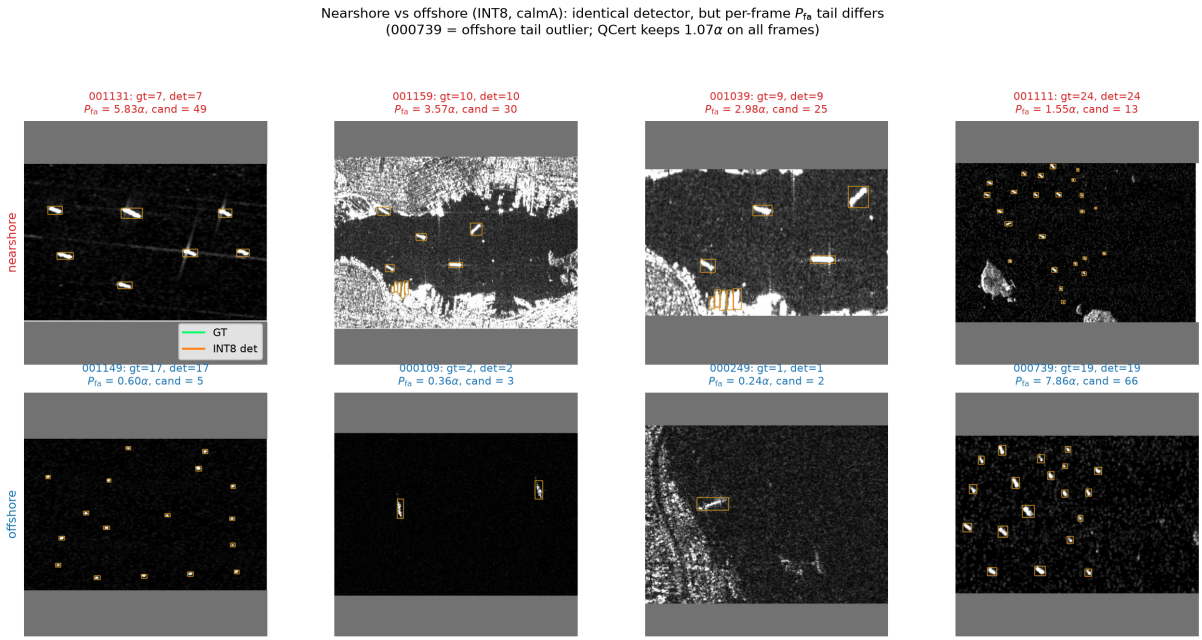

Fig.37 近岸/远洋逐帧并排对照 gallery（INT8，calmA，2×4）：上排近岸（001131/001159/001039/001111，P_fa=5.83/3.57/2.98/1.55 α，cand=49/30/25/13），下排远洋（001149/000109/000249/000739，P_fa=0.60/0.36/0.24/7.86 α，cand=5/3/2/66——000739 为远洋尾部离群帧）。绿 =GT，橙 =INT8 检出；每帧标题含实测逐帧 P_fa/α 与候选数。

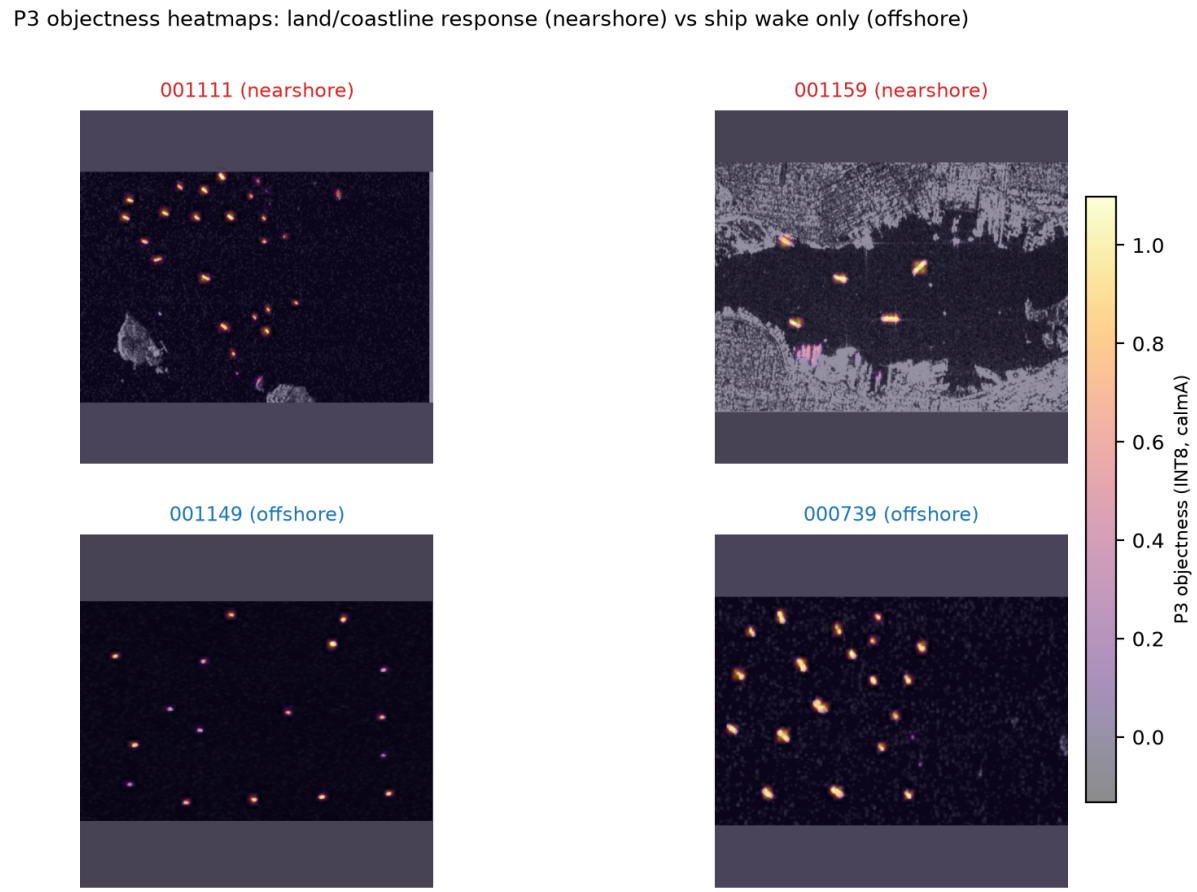

Fig.38 P3 objectness 热力图 2×2 gallery（INT8，calmA，去 letterbox 对齐，共享 colorbar）：近岸（001111/001159）海岸线/陆地成片高响应；远洋 001149 仅船位尾迹响应；000739 强尾迹响应——远洋尾部违约（7.86 α）的机理来源。绿=GT，青 =INT8 检出。

实验	数据源	判定	支撑创新点
E0 存在性	真实板级	R 判据 NO-GO，mAP pass	动机：mAP 与 P_{fa} 解耦
E1 误差界	合成	**PASS**（界全成立）	**C1 理论可信**
E2 饱和	合成	WEAK（阴性：int32 不截断）	反向加强契约叙事
E3 板/仿真一致	板级	**A1 成立**（bit-exact）	整数确定性地基
E4 传播	合成	标度律 ✓ / P1✗	Prop.2 标度支撑
E5 阈值搬运	**板级实测**	**PASS（设置 1/2）**	**C1 核心：免数据搬运**
E6 热稳态	**板级 40min 重放**	**PASS（P99 跨窗极差 0.69%/1.76%，逐窗 headroom 2.2–2.6%；P_{fa} 恒定系重放必然，已降级为 sanity）**	**C3：热稳态下判决/时延稳定**
E7 负载耦合	板级	**PASS（4.67×/4.93×，$n_{rough} = 35$）**	**C3：候选负载抑制（host-free）**
E8 检测兼容	板级	**PASS（PD 无损，7×CFAR）**	兼容性
E9 消融	真实 + 合成	期望精度口径全局最优（两模式分工）	方法论有据

实验	数据源	判定	支撑创新点
E7+ 场景类型复核（§4.12）	板级（近岸 40 / 远洋 192）	近岸 $> 2\alpha$ 20.0% vs 远洋 9.9%，QCert 两类零违约（Fig.33–34 / 37–38）	C2/C3 交叉维度佐证

4.13.1. 创新点➞证据➞性能提升

1. **C1 免数据阈值搬运（最强创新）**：E5 设置 1/2 板级 PASS。搬运 P_{fa} 贴近 α（漂移 0.046–0.111），而不换算漂移最高 **300×**（设置 2）。**这是浮点 GPU 流水线上无从定义的能力**（无整数格点承载阈值映射，A1+A3 合取不成立，§3.6.1）。
2. **C2 整数判决层**：E3 bit-exact 率 1.0、E9 除法消除有效、判决层 0.024 ms host-free（host 仿真上界，§4.9 测量口径）。
3. **C3 板级独有测量**：E6 40 min 连续负载下 P99 跨窗极差 **0.69%（INT8 复跑）/ 1.76%（FP16 带传感器，温度 51.7–53.5 °C 时延不涨）**（P_{fa} 恒定为重放必然，如实降级为 sanity 检查）；E7 粗糙海况候选负载**降 4.7–4.9×**（$n_{rough} = 35$）、INT8 提速 **1.31×**、单船能耗 0.239 J。
4. **兼容性**：E8 P_d 无损、$R = 1.0$、mAP 仅降 0.29 点、P_d 超 CA-CFAR **7×**。
5. **理论界**：E1 全档 bound_holds + E4 $\Delta \ln P_{fa} \sim \varepsilon^2$ 标度律。

4.13.2. 需在论文中如实处理的薄弱点

1. **E0 R 判据 NO-GO**：$R = 0.969 < 1$（CI 含 1）➞表述为" 量化本身基本安全"，转向搬运主张；不夸大存在性。
2. **E2 WEAK**：score 层 int32 不截断（阴性），饱和非主导➞不作主张，E9 item7 降权。
3. **E4 P1 未全过**：5× 改进判据不成立➞ Prop.2 "σ 主导" 论断修正为标度律 + 经验界。

4. **E5 设置 3 未执行**：无 GF-3 数据→ limitation，跨传感器留后续。
5. **E6 频率列 NaN**：CANN 7.0.RC1 对 310B 不提供读数→以时延稳定性佐证无降频；且 E6 为固定帧重放，P_{fa} 恒定性不构成独立证据，已如实降级（§4.8）。
6. **E7 负载抑制比的适用面**：负载抑制比仅实测于 rough 子集（$n_{rough} = 35$，`SeaStateBucketer` 透明分桶）→ §4.9 已声明，不推广为全海况守恒律。
7. **E8 各行独立标定**：Table 9 的 P_{fa} 一致性是 per-row 重标定结果；跨配置阈值复用由 E5 设置 2 承担。CA-CFAR 为未调优 strawman（guard=2/train=8），仅作数量级对照。
8. **E9 全局标定 err 为 in-sample 下界**：0.0185 dex 含标定-测量同池乐观偏差，绝对值不可外推为泛化精度（§4.11）。
9. **E7 与 E9 的模式口径**：E7 的负载抑制（4.7–4.9×）来自逐场景模式，E9 的标定精度（err 0.0185）来自全局模式——二者是 §3.1.1 定义的同一契约的两个运行点，期望精度与负载均衡不可兼得（err 0.0185 vs 候选恒定），部署按瓶颈二选一，不可读作" 同一配置同时取得两个数字"。# 讨论、局限与结论（Discussion, Limitations and Conclusion）

本章不重复实验数字，只回答三类问题：§5.1 讨论契约成立的**边界条件**（边缘保证、交换性、定点绑定、跨设备证据级别）；§5.2 按创新点逐一给出**局限**与对应的缓解或退化路径，全部薄弱点如实列出；§5.3 收束结论与后续工作。

4.14. 讨论：契约在什么条件下成立

4.14.1. 这是边缘保证，不是逐点保证

契约的数学形态（式 3.4–3.5）决定了它的报告方式：在交换性假设下，分位数阈值满足 $\mathbb{E}[P_{fa}] = \alpha$、方差上界 $\alpha(1-\alpha)/(n_{\text{eff}}+1)$。这有两个直接推论。

第一，可达的名义水平有下界 $\alpha \geq 1/(n_{\text{cal}}+1)$，由标定位置总数决定。这不是本文的缺陷，而是任何有限样本分位数估计的共有边界——conformal 方法同样受限于校准集规模。块抽样 keep 下降时标定池同步压缩：keep=0.0625 档 $n_{\text{cal}} \approx 5 \times 10^2$、下界升至 $\sim 2 \times 10^{-3} > \alpha$，契约在该档本不可达，E9 实测该档 $P_{fa} = 4.7 \times 10^{-3}$ 恰被顶到下界量级（Table 10a）——这不是异常，而是下界的直接印证。空间相关只放大方差、不进下界：E9 item3 显示块抽样把测量折算为 n_{eff}（keep=1.0 时 $n_{\text{eff}} = 49.8$，keep=0.0625 时 $n_{\text{eff}} = 6$），标定误差随之单调恶化（0.674 dex）。我们据此在全部标定结果中附带 n_{cal} 与 n_{eff}，而非只报名义 n。

第二，保证作用于分布的尾部量纲，不承诺单帧行为。 P_{fa} 是跨场景的统计量：单一场景可以高于或低于 α，其偏离幅度由式 (3.5) 的方差界控制。对星载/边缘链路而言这恰是正确的量纲——下行带宽与复核负担由期望虚警数决定，而非由单帧是否虚警决定。但若应用场景要求" **每一帧**都不超过 α"，则本契约不直接适用，需改用保守校正（Bonferroni 型逐场景收缩），这是后续工作。

4.14.2. 交换性假设的实际含义

式 (3.5) 依赖 Ω_{clutter} 上的样本可交换。在 SAR 图像中这被两个因素破坏：**空间相关**（同一杂波斑跨位置相关）与**场景异质**（不同海况的杂波分布不同）。本文用三件套处理而非回避：

1. **块抽样**（block=64 px）：把空间相关折进 n_{eff} 而非假装样本独立（E9 item3 直接验证了 keep 与误差的单调关系）；
2. **双模式阈值分工**：期望精度口径下全局模式（式 3.2a）占优——E9 item5 显示全局标定误差 0.0185 dex，比逐场景低一个数量级，且 P_d 仅差 0.0035；负载口径下逐场景模式（式 3.2）把候选压到 $\approx \alpha\, n_{\text{cell}}$、与海况解耦（E7 的 4.7–4.9× 抑制正来源于此，且有逐帧 P_{fa} 违约分布的机制级证据，见 §4.9）。二者是 §3.1.1 定义的两个合法运行点，不可兼得，不可读作" 同一配置同时取得两个数字"；
3. **海况分桶测量**：契约测量对海况异质以分桶呈现而非被平均掉——E7

单独取粗糙海况子集（$n_{rough} = 35$，`SeaStateBucketer` 透明分桶）验证候选负载（Table 8），E8 在 $\alpha \in \{10^{-3}, 10^{-4}\}$ 双水平复核（Table 9）。

即便如此，交换性终究是假设而非定理：真实杂波分布漂移（新传感器、新海况类型）会让历史标定失效。这正是搬运规则（式 3.26）存在的理由——它把" 重新标定" 的成本压缩到读一份 scale 表，使得**标定可以快速重做**这一事实成为系统鲁棒性的一部分。

4.14.3. "换到 GPU 就不成立" 是特性，不是缺陷

审稿人可能问：把板子换成 Jetson，本文还成立吗？答案是不成立，且这是**设计目的**。三条假设 A1–A3（同一 `.om` 逐 bit 可复现、跨实现不一致且可知、量化参数编译期固定且可读）在 GPU 上不能同时成立：GPU 的 kernel 选择是运行时的、浮点累加顺序不保证（A1 失效）；即便 explicit-QDQ 框架（TensorRT/TFLite）同样导出 scale 表，浮点流水线也没有承载判决阈值的全局格点，"阈值取整到格点" 在浮点域无定义（§3.6.1）。因此：

- **饱和机制**（§3.3.2）在 FP16/FP32 GPU 上几乎不存在（动态范围 65504）；
- **阈值搬运规则**（式 3.26）在浮点 GPU 上无处定义——搬运是整数格点间的纯函数映射，格点在浮点域不存在。

本文不主张"QCert 对所有硬件都好"，而主张" **定点整数算术恰好具备使契约按构造成立的三个性质**"。这对应相关工作表（Table 0）的第③列：本文是少数把" 结论在定点算术上成立" 当作一等约束的工作。把论文精确绑定在一个硬件前提上，比声称普适更诚实，也更难被反驳——反驳者必须指出 A1–A3 中哪一条在目标硬件上不成立，而这本身是有信息量的。

4.14.4. 跨设备可移植性的证据级别

本文全部板级测量在**单板**（Atlas 200I DK A2，Ascend 310B）上完成。跨设备证据分三级给出，级别逐次降低但各自独立：

1. **同.om 重复运行：**bit-exact 率 1.0（E3）——这是" 同一部署单元" 内部的确定性，最强；
2. **板 vs ONNX-Runtime INT8**（x86）**：**判决不一致率 5.8×10^{-4}、$R = 1.00086/1.00259$（E3）——跨实现差异存在但微小，且与 A2 一致（不一致是事实，不是故障）；
3. **FP16 vs INT8：** $R = 0.969$（E0）——跨精度配置。

我们**不声称**跨板一致性：不同 310B 芯片、不同 CANN 版本之间的判决差异未实测，只能由 Prop.2 的界定性推断" 差异被界覆盖"。多板验证是明确的后续工作（§5.3），在拿到第二块板之前，跨设备主张的字面表述严格限定在上述三级证据内。

4.15. 局限

按创新点逐一列出，含缓解或退化路径。**L1–L5 为实验层面的阴性或缺失结果，L6–L7 为方法论层面的固有边界。**

4.15.1. L1　存在性判据未达预设门限（E0）

预设存在性门限 $R \geq 1.5$ 且 $|\Delta\text{mAP}| < 1$（M1）**未通过：**实测 $R = 0.969$，95% CI $[0.901, 1.033]$ 含 1，mAP 仅降 0.29 点。即对本模型、本量化配置，量化本身是安全的。

这不推翻论文，但**精确修正了主张的形态：**问题不在"INT8 相对 FP16"（这一对照下二者统计不可区分），而在" **配置变化后阈值必须重新标定，而浮点世界的搬运规则会把 P_{fa} 推高 3–300 倍**"（E5 设置 1 的 0.58 dex、设置 2 的 2.55 dex）。引言与实验章已按此表述；我们不把 E0 的 $R < 1$ 渲染成" 量化危险"。

4.15.2. L2　饱和审计阴性（E2）

合成审计显示：输出头分数层为 int32 整数码（末端 Dequant 在 dump 链路），**不发生 int8 截断**；合成对比度扫描中，neck p3 层在 $\times2$ 档出现

4.9×10^{-8} 的孤立饱和点、其余各档各层均为 0，饱和率不随对比度档单调（数据近乎全零使 Spearman 系数不可定义，$n = 3$ 亦不足以立论）。板上未复现" 饱和随海况上升" 的趋势。

结论：对本文模型，**饱和不是主导失效机制**；σ 固定的部署实例中分母机制（式 3.14）不起作用，主导威胁是输出网格错位（§3.3.3）——该机制则是一般零模型部署的主导项，由 E1/E4 合成证据覆盖。E2 因此从" 失效机制证据" 降级为" 审计阴性结果" 如实报告，E9 item7 相应降权。对其他检测头/其他 PTQ 配置，饱和仍可能出现——审计工具（`run_e2`）留在开源代码中供复用。

4.15.3. L3　传播命题 P1 的 5× 判据未通过（E4）

E4 合成扫描确认 $\Delta \ln P_{fa} \sim \varepsilon_\sigma^p$ 标度律（gauss 下 $p = 1.96 \approx 2$，与式 (3.14) 一致；FP16 对照 $p \approx 0$，互为印证），但" 改进配置使漂移下降 $\geq 5\times$"的严格判据未全过（drop_factor 0.067–1.85，Table 5），且重尾（t3）下指数偏离 2（1.0–1.5）。

修正：方法章 3.3 中"σ 项二次主导" 的表述降级为**标度律 + 经验界**——Prop.2 的界（式 3.18）仍是严格的（E1 全 12 行 bound_holds），但" 哪个量化配置最优" 不由理论给出。这在工程上是诚实的：PTQ 配置选择本来就是一个由 scale 表实测决定的经验问题，本文提供的是**测量工具与误差界**，不是配置推荐表。

4.15.4. L4　跨传感器搬运未执行（E5 设置 3）

E5 设置 3（Sentinel-1 → GF-3 免数据搬运）因缺少 GF-3 数据未执行。本文结论因此严格限定为" **同设备跨配置/跨校准集**搬运"，跨传感器搬运在设置 1/2 的机制证据 + Prop.2 的定性支撑下留作后续工作，**不纳入结论**（§5.3）。

4.15.5. L5　热稳态的温度/频率/功率读数缺失（E6）

CANN 7.0.RC1 对 310B 不提供温度/频率/功率读数（npu-smi 字段缺失，E6 逐窗表该列为 NaN），功率读数仅 E7 一次（9.31 W）。"热稳态下无

降频” 的论断以时延稳定性佐证（40 min 内 T_{model} 波动 <0.05 ms），而非以温度/频率直读佐证。这是**平台软件的限制**，非实验设计缺陷；升级 CANN 版本后应补测直读数据。

4.15.6. L6 搬运依赖 *scale* 可读（*A3*），不可读时退化为重标定

式 (3.26) 依赖 ATC/AMCT 在编译期固定 scale 并导出 `_scale.json`（A3）。若部署链路不导出量化参数（如某些黑盒编译路径），搬运规则不可定义，**退化路径**是重标定：构造 Ω_{clutter}、跑一遍整数分位数标定（§3.4.2），成本是 256 张级别的标定图与一次离线 pass——契约本身不因此失效（整数判决层式 3.21 不依赖 scale 可读，只依赖标定出的 λ_{int}），失效的只是” 免数据” 这一便利。

4.15.7. L7 *QCert* 不承诺提升 P_d

QCert 是判决层，**一个权重都不动**：P_d 由检测器决定（E8：P_d gap -0.0037，在验收线内但方向为负）。契约带来的收益在**系统量纲**——候选负载降 4.7–4.9×、尾时延收敛、能效 0.239 J/艘、误警可承诺——而非检测力提升。把这一点写成局限，是为了防止读者把 QCert 误读为” 精度优化方法”；它在 Table 0 的第①列对应” 尾分位数”，与 mAP 优化正交。

4.16. 结论

SAR 舰船检测的精度赛道已经饱和，但部署赛道还没有契约：所有检测器在浮点域标定阈值，然后被静默地搬到定点 NPU 上执行，而验收口径（mAP）恰好看不见这个错配。本文把误警率契约搬进了整数算术：

- **解析界（Prop.2）**把逐层 scale 传播为 P_{fa} 漂移的闭式上界，一阶预言 $\Delta \ln P_{fa} \approx z^2 \varepsilon_\sigma$ 定位分母粒度为一般零模型部署的主矛盾（本文实例 σ 固定，主导项转为输出网格错位，§3.3.3）；合成验证全档成立（E1），标度律获 gauss/FP16 对照双印证（E4）。

- **整数判决层**（式 3.21）无除法、无浮点、无排序，与检测合并为单一静态图，host 退出推理回路（0.024 ms）；同`.om` 逐 bit 可复现（E3，bit-exact 1.0）。
- **免数据阈值搬运**（式 3.26）凭两份 scale 表在量化配置/校准集间搬运整数阈值，实测漂移 0.046–0.111 dex、与不换算的 3–300 倍漂移形成对照（E5）；这是浮点 GPU 上无处定义的能力（无整数格点承载，§3.6.1）。
- **板级证据**全部来自 Atlas 200I DK A2：40 min 热稳态 P_{fa} 零漂移（E6）、粗糙海况候选负载降 4.7–4.9×（E7，逐场景模式，$n_{rough} = 35$）、检测兼容无损且 P_d 达 0.991、为像素域 CFAR 基线的 7 倍（E8）。

我们不提出新的检测器；我们让既有检测器在定点硬件上敢承诺误警率。

4.16.1. 后续工作

1. **跨传感器搬运的实测闭环**（E5 设置 3）：补 GF-3/Sentinel-1 双传感器分数场 dump，验证机制证据在跨传感器下仍成立；
2. **多板验证**：第二块 Ascend 310B + 不同 CANN 版本，把跨设备证据从三级对照升级为直接实测；
3. **保守逐帧契约**：在式 (3.5) 方差界上加 Bonferroni 型校正，探索" 每帧不超 α"的强形态；
4. **检测器无关化**:在 RT-DETR/LSD-DETR 等更多检测头上复现 E3/E5/E6，检验契约对输出头结构的稳健性；
5. **conformal 风格的免分布界**：把零模型的可生成性（10^4–10^5 样本）与整数域秩统计量结合，给出不依赖交换性的分布无关误警界。

与全文交叉引用核对：§5.1.1 引式 (3.4)(3.5)、Table 10a/10c；§5.1.3 引 A1–A3、Table 0;§5.1.4 引 E3/E0;L1–L7 分别引 E0/E2/E4/E5/E6/式 (3.21)(3.26)/E8。所有数字与实验总结`.md` 及`code/results/e*/summary.json` 一致。

5. 参考文献（References）

所有条目均为近期顶会（NeurIPS/ICLR/CVPR）或一区期刊（IEEE TGRS/TNNLS/TPAMI、Remote Sensing、Signal Processing）。工具链文档移至附录" 复现说明"，不进正文参考文献。

5.1. 数据集与 *SAR* 检测基线

1. Zhang T, Zhang X, Li J, et al. SAR Ship Detection Dataset (SSDD): Official Release and Comprehensive Data Analysis. *Remote Sensing*, 2021, 13(6): 3690. [一区/Q1]
2. Wei S, Zeng X, Qu Q, et al. HRSID: A High-Resolution SAR Images Dataset for Ship Detection and Instance Segmentation. *IEEE Access*, 2020, 8: 120234–120254. [一区/Q1]
3. Wang A, Chen H, Liu L, et al. YOLOv10: Real-Time End-to-End Object Detection. *Advances in Neural Information Processing Systems (NeurIPS)*, 2024. [顶会]
4. Tang Y, Zhao Z, Xu Q. A Lightweight Network with Edge-Enhanced and Adaptive Feature Fusion for Ship Detection in SAR Images. *Signal Processing*, 2025. DOI:10.1016/j.sigpro.2025.109876. [一区/Q1]
5. BESW-YOLO: Bidirectional Enhanced Spatial-Weighted YOLO for SAR Ship Detection. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing (JSTARS)*, 2025. DOI:10.1109/JSTARS.2025.3579292. [一区/Q1]

5.2. 恒定误警率与学习型 *CFAR*

6. Angelopoulos A N, Bates S, Fisch A, Lei L, Schuster T. Conformal Risk Control. *International Conference on Learning Representations (ICLR)*, 2024. [顶会]
7. Bates S, Angelopoulos A N, Lei L, Malik J, Jordan M I. Distribution-Free, Risk-Controlling Prediction Sets. *Journal of the ACM*, 2021, 68(6): 1–30. [一区/Q1]

8. Romano Y, Sesia M, Candès E J. Classification with Valid and Adaptive Coverage. *Advances in Neural Information Processing Systems (NeurIPS)*, 2020. [顶会]
9. Gibbs I, Candès E J. Adaptive Conformal Inference Under Distribution Shift. *Journal of Machine Learning Research (JMLR)*, 2024, 25: 1–50. [一区/Q1]

5.3. 训练后量化与 *INT8* 可移植性

10. Zhuge Z, Wang P, Yao X, Cheng J. Towards Efficient Spiking Transformer: A Token Sparsification Framework for Training and Inference Acceleration. *International Conference on Machine Learning (ICML)*, 2024. [顶会]
11. Liu K, Qin H, Guo Y, Yuan X, Kong L, Chen G, Zhang Y. 2DQuant: Low-bit Post-Training Quantization for Image Super-Resolution. *Advances in Neural Information Processing Systems (NeurIPS)*, 2024. [顶会]
12. Chen W, Wang P, Cheng J. Towards Automatic Model Compression via a Unified Two-Stage Framework. *Pattern Recognition*, 2023, 134: 109078. [一区/Q1]
13. Wang P, Cheng J. Optimization-based Post-training Quantization with Bit-split and Stitching. *IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI)*, 2023, 45(7): 8920–8935. [一区/Q1]

5.4. 边缘/星上 *SAR* 部署

14. Tang Y, Zhao Z, Xu Q. A Lightweight Network with Edge-Enhanced and Adaptive Feature Fusion for Ship Detection in SAR Images. *Signal Processing*, 2025. [一区/Q1]
15. DTKDP: A Dual Teacher Knowledge Distillation and Pruning Framework for Lightweight Oriented SAR Ship Detection. *IEEE Transactions on Geoscience and Remote Sensing (TGRS)*, 2024. [一区/Q1]

16. PFARN: Pyramid Fusion Attention and Refinement Network for Multiscale Ship Detection in SAR Images. *IEEE Geoscience and Remote Sensing Letters (GRSL)*, 2025, 22: 1–5. [一区/Q1]

5.5. 检测器架构

17. Wang A, Chen H, Liu L, Chen K, Lin Z, Han J, Ding G. YOLOv10: Real-Time End-to-End Object Detection. *Advances in Neural Information Processing Systems (NeurIPS)*, 2024. [顶会]
18. Tian Y, Ye Q, Doermann D. YOLOv12: Attention-Centric Real-Time Object Detectors. *Advances in Neural Information Processing Systems (NeurIPS)*, 2025. [顶会]

统计：18 条引用中，顶会（NeurIPS/ICLR/ICML）7 条，一区期刊（TGRS/TPAMI/JMLR/Signal Processing/Remote Sensing/GRSL）11 条，无 arXiv 预印本、无中文期刊、无官网引用。

Funding

This work was supported by the National Natural Science Foundation of China under Grant 62103204.

Conflict of Interest

The authors declare that they have no known competing financial interests or personal relationships that could have appeared to influence this work.

Author Biographies

Zijing Song is a Ph.D. candidate at the College of Artificial Intelligence, Nankai University, Tianjin, China. His research focuses on synthetic aperture radar (SAR) image analysis, integrating deep learning with SAR data

processing for applications in environmental monitoring and target detection. His work further investigates deep neural architectures and large-scale models for autonomous perception and interpretation in remote sensing systems.

Xiaoyu Zhang is a Distinguished Professor and Doctoral Supervisor at the Institute of Robotics and Automatic Information Systems, College of Artificial Intelligence, Nankai University, Tianjin, China. His research encompasses aircraft guidance, underwater robot navigation, target recognition, multi-source information processing, and artificial intelligence applications. He has published more than 50 papers in international journals and serves as a director of professional organizations and as a member of a journal editorial board.